Table of Contents

面向灾害态势推理与辅助决策的多智能体评测：CrisisBench 基准与约束校验 1

摘要 2

1 引言 3

2 相关工作 5

3 任务形式化与 CrisisBench 数据集 7

4 评测协议：三裁判多数票 + 可靠性强制报告 13

5 约束校验组件（Verifier） 14

6 实验 17

7 分析：错误类型学 30

8 局限与伦理 35

9 结论 36

参考文献（依据领域综述整理，正式投稿前逐条补全卷期页码） 36

附记（编务说明：不随投稿正文提交，投稿清样时整段删除） 38

面向灾害态势推理与辅助决策的多智能体评测：CrisisBench 基准与约束校验

论文初稿 v3.1（2026-10-19：v0.4 全量结果 + A6 真实分歧终裁 + A8 成本延迟并入） 配套材料：领域综述 · 路线图 · 评分细则 · 实验结果

摘要

大语言模型（LLM）驱动的多智能体协作已在办公、代码等开放域任务中展现出组织优势，但在灾害应急决策这一高后果领域，目前既缺乏评测多智能体决策质量的基准，也缺少对决策输出进行可信校验的机制。本文提出 CrisisBench——一个中文灾害态势推理与辅助决策评测基准，并配套设计约束校验组件。CrisisBench v0.4 包含 36 个灾害场景（单灾种 14、链式次生灾害 14、信息矛盾 8，覆盖地震、洪涝、山火、化工爆炸/泄漏、台风、泥石流、山洪、城市内涝、低温雨雪冰冻、暴雪、大风、中毒、粮库/民房火灾、水库泄洪、坍塌等 20 余类灾情），共 709 个评分要点，其中 48 条为数值推算型要点，按事实层、推理层、决策层三层组织，采用 checklist 式 0/1 客观判定。为防止智能体直接抄录情报获得满分，每个场景嵌入数值推算型要点（关键数字必须跨多条情报计算得出）与陷阱型、矛盾型要点。基于 glm-4-flash 的试点实验（其前身 v0.3 的 96 要点 × 2 配置 × 3 裁判）表明：（1）多智能体（四角色串行）在三裁判多数票口径下较单智能体提升 5.2 个百分点（95.8% vs 90.6%），在更严格的裁判口径下提升 20.9 个百分点；（2）两个 LLM 裁判之间的 Cohen’s kappa 仅为 0.03~0.08，证明 LLM 作为 checklist 裁判在灾害决策场景中不可互换，三裁判多数票（2-of-3）协议是可行的替代口径；（3）区分度集中于数值推算型要点等”硬要点”，其中苯蒸气扩散时间的推算在三种裁判口径下全部为 0 命中，是当前模型最稳定的失分点。随后，本文完成 v0.4 全量实验（36 场景、709 要点、6 配置、三裁判多数票口径），对上述发现做定量确认：多智能体较单智能体场景级得分高 7.05 个百分点（综合 90.7% vs 83.5%；$p=3.0\times10^{-9}$，95% CI [+3.3, +11.0] pp），与试点 +5.2pp 同量级；审核官消融使多智能体回落 7.32 pp（$p=6.5\times10^{-7}$）；约束校验组件再带来 2.81 pp 增益（$p=2.7\times10^{-3}$，95% CI [+0.1, +6.1] pp），并将资源超配、陷阱、运力缺口类错误压至近零；更强模型 glm-4-plus 较 flash 高 9.11 pp（$p=2.1\times10^{-15}$）、接近天花板；两 LLM 裁判 kappa≈0 而各自自一致率 0.99~1.00，坐实三裁判多数票协议与确定性校验的必要性。A6 人工裁定（8 场景 71 项真实三裁判分歧，终裁 vs flash 一致 88.7%、vs 多数票 78.9%）与 A8 成本延迟统计（multi 约为 single 的 1.86 倍 token）亦已完成。

针对 LLM 裁判不可靠的问题，本文设计了约束校验组件（资源超配审计、数量核算、数值推算核对、情报冲突检查、陷阱处置识别五类确定性规则），并在 v0.4 全量上与 LLM 裁判对照验证其有效性。本文的贡献是一个可复现的中文灾害多智能体决策基准、一套三裁判多数票评测协议，以及一个以确定性规则替代/纠正 LLM 裁判、并经全量验证有效的约束校验组件。

关键词：灾害应急决策；多智能体；评测基准；大语言模型；约束校验；三层评分

---

1 引言

灾害发生后，指挥机构面临海量异质信息（现场报告、社交媒体、气象水文、遥测数据）与极强的时效压力，需要在信息残缺、甚至互相矛盾的条件下快速形成”现在什么情况、下一步会怎么样、该怎么办”的研判结论。大语言模型与多智能体协作框架为此提供了新工具：多个角色各司其职、互相校验，有望将碎片信息组织成可追溯的决策建议。

但这一方向缺少一个基本的评测基础设施。文献调研显示，已有工作分散在四个孤立位置：灾害信息入口（推文分类、地名落图）、灾害知识问答（以知识图谱增强 LLM）、多智能体协作机制（集中在办公、代码、旅行规划域）、以及灾害领域落地（培训模拟 Sim911 测的是”话务员表现”而非”决策质量”，复盘评估 LogiDebrief 做的是事后分析而非事中决策）。**没有人建立过”多智能体灾害态势推理与辅助决策”的决策质量评测基准**——多智能体在灾害决策中究竟是帮推理、还是害事实，知识增强与校验机制在哪里起作用，均缺乏可测量、可复现的证据。与此同时，灾害决策的约束（资源守恒、空间一致性、时序合法性）天然可形式化，却还没有被做成智能体输出之前的”验收关卡”。

针对上述空白，本文做三件事：

1. **构建 CrisisBench 基准**：v0.4 版 36 个中文灾害决策场景（单灾种 14 / 链式次生灾害 14 / 信息矛盾 8）、共 709 个评分要点，采用”事实层 / 推理层 / 决策层”三层标注；场景设计刻意嵌入数值推算型要点（48 条）、矛盾情报与陷阱处置诱导，防止”抄情报即满分”，保证区分度。其前身 v0.3（5 场景、96 要点）已完成基准构建与校准，并作为本文试点实验（§6.3、§6.5）的数据基础。
2. **提出三裁判多数票评测协议**：同一批答案分别由规则匹配器与两个 LLM 裁判独立打分，以 2-of-3 多数票为正式口径，并强制报告裁判间一致率与 Cohen’s kappa。试点中最直接的发现——两个 LLM 裁判 kappa≈0——本身就是方法论文献中 LLM-as-a-judge 不可靠性在灾害决策场景的一次实证。
3. **设计约束校验组件**：把资源超配、数量核算、数值推算、情报冲突、陷阱处置五类检查写成确定性规则，作为决策链的验收关卡，并完成其与 LLM 裁判的对照实验（§6.6）。动机直接来自裁判可靠性实验：最容易出错的核对工作应当交给确定性规则而非 LLM。

试点实验发现（被测模型 glm-4-flash，v0.3 口径 96 要点 × 2 配置 × 3 裁判）：

- 多智能体（情报官→研判官→决策官→审核官串行）优于单智能体：多数票口径 +5.2pp，严格裁判口径 +20.9pp；
- LLM 裁判不可靠：宽松裁判模型接近饱和（99.0% 全对），严格裁判模型系统性收紧且方差大（同一场景同一批答案差 12 分），两者 kappa≈0；
- 区分度来自”硬要点”：数值推算型要点是全部配置的失分点，其中”推算苯蒸气到达居民区时间”三种裁判全票 0；多智能体的增益来自审核环节对”遗漏型错误”的补全（修复 2 个单智能体拿不到的计算型要点）。

在此基础上，本文已完成 v0.4 全量实验（36 场景 × 709 要点 × 6 配置：single / multi / multi-noaudit / multi-verify @glm-4-flash，single / multi @glm-4-plus），沿用三裁判多数票口径，核心结果如下：

- **多智能体增益方向一致、量级与试点相当**：multi 较 single 场景级均值高 7.05pp（多数票口径综合得分 90.7% vs 83.5%；McNemar $p=3.0\times10^{-9}$、Wilcoxon p=0.0008，95% CI [+3.3, +11.0] pp），与 v0.3 试点 +5.2pp 同量级（试点 5 场景、全量 36 场景，场景集不同，不宜直接相减）（§6.3）。
- **审核官与约束校验组件各有可量化的增益**：去掉审核官后 multi 回落 7.32pp（$p=6.5\times10^{-7}$，§6.4）；在完整 multi 上引入 Verifier 再 +2.81pp（$p=2.7\times10^{-3}$，§6.6），主要压住资源超配、陷阱、运力缺口类错误。
- **更强模型接近天花板**：glm-4-plus 在 multi 配置下较 flash 高 9.11pp（$p=2.1\times10^{-15}$），36 场景中 35 个满分，multi 与 single 已无显著差异（McNemar 二项精确 p=1.0）——提示本基准对强模型的区分度趋于饱和，需在 v0.5 引入更难场景或更高区分度的硬要点子集。
- **裁判可靠性结论在全量上复现**：两裁判 kappa 全部接近 0（multi@flash 0.081、single@flash 0.079、其余 −0.008~−0.003），flash 裁判自一致率 single 0.99、multi 1.00（§6.5）。
- **A6 人工裁定与 A8 成本已完成**：8 场景抽取 71 项真实三裁判分歧做终审裁定，人-机一致率 vs flash 88.7%、vs 多数票 78.9%（§6.5）；成本上 multi 约为 single 的 1.86 倍 token、2.0 倍调用（§6.8）。

---

2 相关工作

本节按”灾害信息入口 → 知识增强推理 → 多智能体协作 → 灾害领域落地”四个链段简述与本工作最相关的研究（完整调研见配套综述）。

灾害信息入口。 从碎片信息到结构化要素是决策的前置环节。早期监督分类模型依赖标注且跨灾种泛化差；近期工作系统评测了 LLM 零样本分类在危机推文上的表现，发现其仍低于监督基线，且洪水类别、求助类信息、错别字文本是三类显著软肋 [危机推文评测, WWW’25]。地名落图与遥感综合解读等工作把 LLM 感

知能力推进到定位层面 [DisasterTD; RescueADI]，但都止步于感知层，未进入决策层。

知识增强推理。 KG 增强 LLM、GraphRAG、闭环自修正与时序演化是该链段的发展主线 [RAG; E-KELL; GraphRAG 综述; CogMG; 时空 KGQA]。代表性的灾害领域工作是 E-KELL：以知识图谱与 LLM 支撑危化品泄漏应急决策，改进以专家主观评分衡量的决策辅助形态，并非多智能体研判结构。通用知识增强技术已相当成熟，“拼装”难度不大；空白在于灾害领域的定制（因果链表示、时空约束与决策挂钩）与评测。

多智能体协作。 从 ReAct 的单智能体”想一步做一步”，到 AutoGen 的对话式多角色协作、自动编排与成本调度、以及带验证函数、程序性记忆与多约束规划的闭环框架 [ReAct; AutoGen; MetaAgent; VeriMAP; LEGOMem; PMC]，协作范式已经由”提示词工程”变成”系统工程”：状态机、验证函数、记忆库齐备。**但这些机制的评测全部位于数学、代码、旅行、办公域，没有一项针对灾害决策的独特约束**（致命后果、时间压力、信息残缺、链式次生灾害）进行过建模与评测。

灾害领域落地。 已有四个分散的脚印：Sim911 用 LLM 扮演 911 调度员做培训模拟，其评测口径是学员表现而非系统决策质量 [Sim911, AAAI’25]；LogiDebrief 把演练复盘需求转成信号时序逻辑公式自动判定，属于事后评估 [LogiDebrief, IJCAI’25]；E-KELL 面向问答；DisasterTD/RescueADI 面向感知。“多智能体协作研判决策”这一段是空的——本文的 CrisisBench 正是填补这一空白，而约束校验组件则承接 VeriMAP”每子任务配可执行验证函数”的思路，将其灾害化：把资源守恒、数值推算、情报一致性写成验收规则。

3 任务形式化与 CrisisBench 数据集

3.1 任务定义

给定一个灾害决策场景，形式化为五元组 (灾种，时间点，情报片段集合 I，可用资源清单 R，三层评分要点)。其中情报片段 I 为多来源（通报 / 现场 / 社媒 / 气象），可含干扰、矛盾与错误处置诱导；资源清单 R 显式列出可调用资源与”无”项（如”无直升机”）。被测系统需输出三层研判结论：

- **事实层**：关键情报要素是否捡全、关键数值是否推算正确；
- **推理层**：因果结论是否推出、是否敲定；
- **决策层**：行动建议是否有具体对象与动作、资源是否可行、是否与已确认事实冲突。

评测以逐条 checklist 客观判定 0/1（§4），不存在 0.5 分。该设定把”多智能体灾害研判”从开放生成问题约束为可评分、可复现的基准任务。

3.2 数据集概览（v0.4）

CrisisBench v0.4 共 **36 场景、709 个评分要点**，按难度分三类：

类别	场景数	场景编号	每场景要点	要点小计	设计特征
单灾种	14	S002、S003、S006~S017	18~19	259	单一灾因，考信息捡全与标准处置
链式（次生灾害）	14	S001、S004、S018~S029	18~21	283	主灾触发次生链，考态势演化与连锁处置

类别	场景数	场景编号	每场景要点	要点小计	设计特征
信息矛盾	8	S005、S030~S036	20~21	167	每场景 ≥2 组矛盾口径，需保守处置 + 统一口径上报
合计	**36**	—	18~21	**709**（含 48 条数值推算型要点）	每场景事实 8~9 / 推理 4~5 / 决策 6~7

其中 **S001~S005 为 v0.3 原版（96 要点，其历史实验数据与本文试点引用不变）；S006~S036 为 v0.4 新增（613 要点）**。灾种覆盖：地震、洪涝、山洪、泥石流、滑坡、台风、暴雨内涝、低温冰冻、暴雪、大风、山火、粮库火灾、民房火灾、化工爆炸/泄漏、加油站、硫化氢中毒、厂房坍塌、水库泄洪等（按 rubric.md §五逐场景准确清单为准）。

v0.3 五个原版场景的层分解如下（保留为基准构建与试点实验证据）：

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
S001	地震	链式次生灾害	震后 5 小时	8/4/6 = 18	撤离规模需推算（240 户×1-2 人）；帐篷缺口陷

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
					阱；土木房余震风险
S002	洪涝	单灾种	特大暴雨第 2 天	8/4/6 = 18	被困总数汇总（约 200 人）；医院 4 小时保电窗口；私家车乱入
S003	山火	单灾种	火起第 3 小时	8/5/6 = 19	火头到达时间推算（4-6 小时）；夜间降温≠火势减弱；村民上山
S004	化工泄漏	链式次生灾害	泄漏发生 1 小时	9/5/7 = 21	苯蒸气 8-9 分钟到达推算；水冲稀释陷阱；邻近储罐次生爆炸
S005	台风	信息矛盾	灾中	8/5/7 = 20	三组数据矛盾；冲

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
					锋舟 2 艘 vs 8 艘运力缺口；调头传言

v0.4 新增场景（S006~S036）均沿用同一层分解规范：事实层 8~9、推理层 4~5、决策层 6~7，合计 18~21 要点；每场景带 1~2 条数值推算要点与 ≥1 个陷阱；S030~S036 为信息矛盾类。

3.3 场景规范与构建流程

情报构成。 每场景 8~11 条多来源情报（通报 / 现场 / 社媒 / 气象四类来源混合），刻意混入 1~2 条**干扰情报**（与决策无关但易诱导展开，如”邻县消防大队刚完成演练”）。 信息矛盾类场景额外制造 ≥2 组**矛盾口径**（同一指标出现冲突数值）。此外，情报中会有人物**提议错误做法**（如”用消防水带直接冲洗地面苯液”“按台账数调度”“徒手堵漏”），对应决策层的陷阱要点。

资源清单。 每场景 4~6 项资源清单，且**必含”无 X”否定项**（如”无直升机”），用于资源超配陷阱的判定。

数值推算型要点。 每个场景设 1~2 条，要求关键数字不直接出现在情报里，必须跨 ≥2 条情报计算得出。代表性例子：

推算要点	情报原料	推算公式	期望区间
S001-F8（转移规模）	两村约 240 户、每户留守 1~2 人	240×(1~2)	300~500 人

推算要点	情报原料	推算公式	期望区间
S003-F8（火头抵近）	火线距村 6 km、蔓延 1~1.5 km/h	6÷(1~1.5)	4~6 小时
S004-F9（苯蒸气到达）	距居民区 2 km、风速 4 m/s	2 km÷4 m/s	8~9 分钟
v0.4 新例（堰塞湖漫顶）	坝前水位距漫顶 3 m、上涨 0.5 m/h	3÷0.5	约 6 小时
v0.4 新例（抽排时长）	18 台泵 × 200 方/时，待排 6 万方	60000÷(18×200)	约 16.7 小时

陷阱要点与矛盾要点。 陷阱型要点以”必须识破错误做法并给出正确做法”方式表述（识破 + 正确做法做对才得分）。信息矛盾类场景（S005、S030~S036）强制包含：≥2 组矛盾口径、“按保守口径处置并核灾”要点、以及”统一数据口径 / 逐点上报”决策要点。

场景以中文撰写，素材原型取自公开灾害调查报告与通报中的典型要素（水库裂缝、隧道被困、隔离带缺失、泄漏入河等），投稿前由标注人逐条复核其合理性。

3.4 三层评分细则（checklist 式客观判定）

所有要点按三层组织，**每个要点独立判 0/1，不存在 0.5 分**，且”采点不算错点”——只检查”该说的说了没有”，不惩罚无关内容（决策层出现硬伤除外）。判定采用 checklist 式，同义替换（“撤离”=“疏散”）算命中。

- **事实层（F）**：回答是否捡全关键情报要素。**数值推算型要点**：关键数字不直接出现在情报里，回答必须给出**推算出的数值或数值区间**才算满足；只复述情报里的原始数字不算。裁判对照情报原文核验数值。

- **推理层（R）**：判定对象是**结论**——回答明确表达出该条目结论（措辞可不同、意思到位、不与情报矛盾）得 1；结论未出现或相反得 0。场景 JSON 中保留的”起点/机制/终点”字段仅供人工核对与论文展示因果结构，不作为裁判逐字对号要求（v0.2 经验：逐字对号会使裁判方差爆炸）。
- **决策层（D）**：每条建议**有具体对象 + 具体动作**得 1；笼统表述（“加强力量”“做好工作”）得 0。出现下列任一硬伤，该条不得分并记录原因：① 无对象；② **资源超配**（动用资源清单之外的资源）；③ 与情报冲突（如道路已断仍”通过县道撤离”且未提绕行）。陷阱型要点以”必须识破错误做法”的方式表述，识破并给出正确做法才得分。

三层得分均为命中数/要点数，综合得分取三层等权平均仅作总览排序用；论文正文以分层结果为主。

3.5 两轮校准记录与 v0.3→v0.4 扩容

基准构建过程保留了两次校准记录（数据文件随基准公开），这本身构成论文”基准构建方法论”部分：

- **v0.2 教训一：事实层满分无区分度。** 情报直接送达被测智能体，事实要点几乎都能抄到，全配置接近满分。→ v0.3 为每个场景新增 1~2 条**数值推算型要点**。
- **v0.2 教训二：裁判方差过大。** 同一批回答，glm-4-flash 原提示词几乎全判 1，glm-4-plus 加”宁严勿松”提示词后推理/决策层几乎全判 0。→ v0.3 双管齐下：① 要点全部改写为**可客观核验的具体结论/具体措施**；② 裁判提示词取中间口径，并保留双模型交叉裁判。

v0.3→v0.4 扩容策略。 试点结果显示，本基准的区分度不在聚合分数、而在”硬要点子集”（数值推算型、矛盾型、陷阱型，见 §7.1）。据此，v0.4 的扩容不是简单增加情报噪音，而是**把这三类区分度来源点批量复制并推广到 8 类灾种**：数值推算型要点从 v0.3 的 3 条扩充到 48 条；信息矛盾类从 S005 单个场景推广到

8 个场景；每场景强制 1~2 条推算要点 + ≥1 个陷阱。同时统一每场景情报条数（8~11 条）与资源清单（4~6 项、含否定项），保证跨场景可比。

---

4 评测协议：三裁判多数票 + 可靠性强制报告

打分实现分两种（细则见 rubric.md §六）：

1. **规则打分（零成本参照）**：逐要点关键词匹配，命中词表即得 1。免费、零波动，但”提到词≠答对”，定位为开发自检与廉价参照，不作为正式分数。
2. **LLM 打分（正式）**：把”情报原文 + 要点清单（唯一编号）+ 被测回答”交给裁判模型，要求逐条输出 JSON 的 0/1 与一句理由；要点注明”推算”的必须核对数值；裁判漏判按 0 分计；解析失败重试一次。裁判与被测模型同 API 但独立调用、角色隔离，温度设为 0。

协议三个要点：

- **多裁判多数票**：每个要点由规则 + glm-4-flash + glm-4-plus 三方独立判定，**2-of-3 多数票为正式主指标**；
- **同批答案换裁判重打分（－rescore）**：保证”分数之差 = 裁判之差、与答案无关”，是裁判可靠性分析的必要设计；
- **强制报告一致率与 kappa**：裁判两两一致率与 Cohen’s kappa 必须随主结果一同报告（试点结果见 §6.5），并由标注人对分歧项人工抽检裁定（对应实验路线 A6，投稿前完成）。人工抽检计划：随机抽 20~30% 场景，逐要点复核分歧项并裁定，报告人-机一致率。

---

5 约束校验组件（Verifier）

5.1 动机

§6.5 表明：把 checklist 核对交给 LLM 裁判，代价是饱和、方差与近乎随机的裁判间一致性。而灾害决策中真正需要核对的许多事项——资源是否超配、数量是否对得上、推算数值是否正确、建议是否与已确认事实冲突——**天然是可形式化的确定性检查**。因此本工作设计一个确定性约束校验组件（VeriMAP 灾害化），置于 multi 流水线中审核官之前：对前序发言（或最终报告）运行规则校验，输出违规清单，交由审核官修正后再出最终报告。组件不替代 LLM 裁判，而承担”最容易出错的核对工作”。

5.2 规则表

编号	类别	检查内容（确定性实现）	对应场景实例
V1	资源超配	决策中出现的每项资源必须属于场景资源清单，或附带”外部调援 + 来源”说明（清单显式列出”无直升机”等否定项）	S001 无直升机却调直升机；S005 按 8 艘冲锋舟部署（实际 2 艘）
V2	数量核算	按清单数量核算运力/安置容量是否满足决策目标规模（人数×趟数与船只数、帐篷数 vs 安置人数）	S005 2 艘×10 人/趟 vs 180 人；S001 帐篷 12 顶 vs 300-500 人

编号	类别	检查内容（确定性实现）	对应场景实例
V3	数值推算核对	对注明”推算”的要点，从情报数值按公式计算期望区间，检查回答中的数值是否落入区间	S001-F8（240×$1_{2\to300}$500）；S003-F8（6km÷$1_{1.5km/h\to4}$6h）；S004-F9（2km÷4m/s→8~9min）
V4	情报冲突	决策中的断言（路线、对象、状态）与”已确认事实”集合（如道路中断）冲突则报错	S001 县道中断仍建议”经县道撤离”且未提绕行
V5	陷阱处置	识别错误处置表述并报错（关键词+词性模板，如”冲洗/稀释+化学品”）	S004 水带冲洗地面苯液；S002 放任私家车自发抽水；S003 村民无防护夜间上山
V6（半自动）	对象完整性	“撤离/救援”类措施必须带具体对象；确定性实现受限，由 LLM 初审 + 规则终审	全场景（模糊措施”做好工作”类）

5.3 伪代码

```
def verify(answer, scene) -> list[Issue]:
issues = []
for r in extract_resources(answer):                    # 实体抽取/词
```

表匹配

```
        if r not in scene.资源 and not has_sourcing(answer, r):
            issues.append(Issue("V1 资源超配", r))
    for target, plan in scene.核算量():                    # 标注人预写的核对条目
        if capacity(plan) < target:                        # 2 艘×10 人/趟 vs 180 人
            issues.append(Issue("V2 运力缺口", target, plan))
    for key, (formula, interval) in scene.数值推算.items():   # 标注人预写的公式与区间
        val = extract_number(answer, key)
        if val is None or val not in interval:             # 未推算 或越界
            issues.append(Issue("V3 推算缺失/越界", key, interval))
    for fact in scene.已确认事实:                           # 道路中断、坝体裂缝等
        if contradicts(answer, fact):
            issues.append(Issue("V4 情报冲突", fact))
    for pattern in scene.陷阱模式:                          # 冲洗+稀释+苯 类模板
        if pattern.matches(answer):
            issues.append(Issue("V5 陷阱处置", pattern))
    return issues
```

要点：**所有规则参数（公式、区间、资源清单、事实集、陷阱模板）由标注人在场景 JSON 中显式给出**，组件本身不含任何训练参数；同一答案运行任意次输出恒定，天然解决 §6.5 的裁判方差问题。

5.4 与 LLM 裁判的对照实验设计（即本文 RQ4）

- **目标①（等价性）**：校验器对试点硬要点（§7.1）与三裁判多数票判定的一致率；预期 V1~V4 完全覆盖计算型与资源型硬要点，V5/V6 为部分覆盖。

- **目标②（增益）**：将违规清单注入 multi 流水线（审核官出报告前强制附载、要求逐条修正），对比 multi+verify 与 multi 的硬要点命中率与总命中率；预期修复 S004-F9、S005-R2 等规则可判要点。
- **目标③（稳定性）**：同一批答案校验器重复运行输出完全一致；与 §6.5 中 kappa≈0 的 LLM 裁判形成对照，量化”确定性校验替代 LLM 核对”的可靠性收益。
- **目标④（成本）**：校验器零 API 调用、毫秒级耗时，与 LLM 裁判每要点一次调用对比（正式版采集 token/耗时后报告）。

上述四个对照目标的实测结果见 §6.6（RQ4）。

---

6 实验

6.1 实验路线

以下实验清单取自路线图第八节（EMNLP 2027 冲刺改造清单）。A1 已完成（对应 §3 的 v0.4 数据集）；v0.3 试点为基准构建与校准阶段的已完成实验（§6.3、§6.5）。**A1、A2、A3、A4、A5、A6、A7、A8、A9 与 v0.3 试点已完成并报告实测数字；仅 A10（人类基线）为可选未完成项，本文不报告其数字。**

编号	实验	回答的审稿问题	状态
A1	场景规模扩展（5→36 场景，v0.4：709 要点 / 48 推算要点）	“5 个场景凭什么叫基准”	已完成
A2	双模型全量（glm-4-flash +	“结论是否只对一家 API 成立”	已完成（§6.7）

编号	实验	回答的审稿问题	状态
	glm-4-plus）		
A3	配置矩阵补全（single / multi / multi-verify；审核官消融）	“增益到底来自哪个角色”	已完成（§6.4）
A4	约束校验组件落地（V1~V5）+ multi vs multi-verify	“校验到底有没有用”	已完成（§6.6）
A5	显著性检验（要点级 McNemar + 场景级配对检验 + 自助法 95% CI）	“差 5.2pp 是运气吗”	已完成（§6.3）
A6	人工裁定与一致率（20~30% 场景逐要点裁定）	“机器裁判和人对不对得上”	已完成（8 场景 71 项真实三裁判分歧，§6.5）
A7	裁判稳定性（同批答案重打分 2 次报自一致率）	“裁判方差被完整量化”	已完成（§6.5）
A8	成本与延迟表（API 调用数 / token / 耗时 / 费用）	“多 Agent 不是白贵的”	已完成（调用数/token/耗时实测；费用待折算，§6.8）
A9	错误类型学定	“错误分析有	已完成（§

编号	实验	回答的审稿问题	状态
	量（8 类错误分布统计）	数据结构支撑” 7.2）	
A10（可选）	小规模人类基线（3~5 名作答对照）	“人类水平参照”	计划中

6.2 实验设置（v0.3 试点 + v0.4 全量）

- **被测智能体（v0.3 试点）**：glm-4-flash（温度 0.1）。两种配置：
  - **single**：单研判员一次性作答”事实要素/态势研判/行动建议”三部分；
  - **multi**：情报官→研判官→决策官→审核官四角色串行；除情报官外每个角色可见前面角色发言（公开对话、可追溯），**以审核官最终报告作为打分对象**。
- **被测智能体（v0.4 全量，6 配置）**：在以上基础上新增 ① **multi-noaudit**（去掉审核官的消融配置，情报官→研判官→决策官，对应 A3）；② **multi-verify**（在 multi 的审核官收口前接入 §5 约束校验组件，对应 A4）；以及 ③ **glm-4-plus** 作为第二被测模型（single / multi 两配置，对应 A2）。
- **裁判**：规则匹配器、glm-4-flash（温度 0）、glm-4-plus（温度 0）；同一批答案由两个 LLM 裁判各打一遍（rescore 机制），以 2-of-3 多数票为正式主指标。
- **规模（v0.4 全量）**：36 场景 × 6 配置 × 709 要点，三裁判多数票口径；v0.3 试点（5 场景 × 2 配置 × 96 要点）作为基准构建与校准证据保留（§6.3、§6.5）。
- **成本结构事实（A8 实测）**：协议口径下 multi 每场景约 6 次 API 调用、single 约 3 次（含同侧裁判与 plus 裁判），multi 的 token 约为 single 的 1.86

倍、耗时约 2.06 倍；Verifier 为零 API 调用（纯确定性规则）。成本-得分散点见图 5（`crisis-bench/figures/fig5_cost.png`），完整成本表见 §6.8。

6.3 RQ1：多智能体是否优于单智能体？（v0.3 试点 + v0.4 全量）

配置	规则打分	flash 裁判	plus 裁判	三裁判多数票(2-of-3)
single（单研判员）	84/96 = **87.5%**	95/96 = 99.0%	56/96 = **58.3%**	87/96 = **90.6%**
multi（四角色串行）	89/96 = **92.7%**	95/96 = 99.0%	76/96 = **79.2%**	92/96 = **95.8%**
multi − single	**+5.2pp**	0（flash 裁判饱和）	**+20.9pp**	**+5.2pp**

分场景明细（命中/总数）：

场景	single 规则	single flash	single plus	multi 规则	multi flash	multi plus
S001 地震	14/18	18/18	14/18	17/18	18/18	17/18
S002 洪涝	17/18	18/18	10/18	18/18	18/18	16/18
S003 山火	18/19	19/19	7/19	17/19	19/19	19/19
S004 化工	19/21	20/21	11/21	20/21	20/21	9/21
S005 台风	16/20	20/20	14/20	17/20	20/20	15/20

结论。 “multi > single” 在规则（+5.2pp）、plus（+20.9pp）、多数票（+5.2pp）三种口径下全部成立；仅在 flash 裁判口径下测不出差异，原因是该裁判已饱和（99.0%）。分层看：multi 的增益不在事实层（两种配置事实层都接近满分，恰是 v0.2 校准期的现象），而来自推理/决策层与个别硬要点；multi 的代价是 4 倍 API 调用与更长的推演链。一个例外值得注意：S004 在 plus 裁判下 multi（9/21）反而低于 single（11/21），结合 §6.5 中 plus 裁判方差偏大的证据，该差异更多反映裁判波动而非配置真实差异——这正是多数票口径存在的意义。**注意：上述为 96 要点试点结论；显著性检验与 v0.4 全量复核见下文。**

v0.4 全量（36 场景，glm-4-flash，三裁判多数票口径）

在 36 场景全量上比较 multi 与 single（被测模型均为 glm-4-flash，多数票口径），场景级得分均值差与统计显著性如下：

指标	数值
综合得分（multi / single）	**90.7% / 83.5%**
场景级得分均值差（multi − single）	**+7.05 pp**（multi 高于 single）
要点级 McNemar 检验	multi 对 single 错的要点 61 条、multi 错而 single 对的要点 10 条；**$p = 2.96\times10^{-9}$**
场景级配对 Wilcoxon 检验	**p = 0.0008**
自助法 95% CI（multi − single）	**[+3.26, +11.04] pp**

结论。 v0.4 全量下”multi > single”结论方向一致且高度显著：综合得分 90.7% vs 83.5%，场景级均值差 +7.05pp（$p=2.96\times10^{-9}$，CI [+3.26, +11.04] pp 不含 0）。与 v0.3 试点多数票口径的 +5.2pp 相比量级相当（试点为 5 场景 × 96 要点、全量为 36 场景 × 709 要点，场景集不同，二者不宜直接相减）：场景扩容（数值推算要点 3→48 条、信息矛盾场景 1→8 个）后”硬要点”占比上升，多智能体在推理/决

策层与硬要点上的补全优势更稳定地体现出来。分层看（图 1，`crisis-bench/figures/fig1_radar.png`）：multi 的增益集中在推理/决策层（multi 推理层 90.2%、决策层 90.6%，single 分别仅 87.2%、78.3%）与个别硬要点，事实层两者都接近满分（multi 91.0%、single 85.5%）；场景×配置的完整热图见图 2（`crisis-bench/figures/fig2_heatmap.png`）。

6.4 RQ2：增益来自哪个角色（审核官消融）（v0.4 全量，glm-4-flash，多数票口径）

为定位多智能体增益来源，在 v0.4 全量上比较 multi 与去掉审核官的消融配置 **multi-noaudit**（情报官→研判官→决策官，无最终审核收口）：

对比	场景级均值差	McNemar（b / c）	Wilcoxon	自助法 95% CI
multi vs multi-noaudit	**+7.32 pp**（multi 更高；综合 90.7% vs 83.5%）	b=76、c=25，**$p=6.52\times10^{-7}$**	**p=0.0006**	**[+2.32, +11.78] pp**

（McNemar 表义：multi 对而 noaudit 错的要点 76 条，multi 错而 noaudit 对的要点 25 条。）

结论。 去掉审核官后多智能体在多数票口径下显著回落 7.32pp（$p=6.52\times10^{-7}$，CI [+2.32, +11.78] pp 不含 0），说明 multi 对 single 的增益中相当一部分来自审核环节。结合 §7.2：noaudit 的”事实丢失→推理缺失→决策未达标”三类错误链式恶化（19 / 20 / 19，远高于 multi 的 0 / 7 / 10），审核官的价值主要体现在收口时的补全与事实核对，而非仅资源类陷阱纠正。

6.5 RQ3：LLM 裁判可靠吗？（v0.3 试点 + v0.4 全量）

同批答案、同一裁判提示词，flash 与 plus 逐条对比：

配置	一致率	Cohen’s kappa	flash=1 且 plus=0	flash=0 且 plus=1
single	59.4%	**0.03**	39 条	0 条
multi	80.2%	**0.08**	19 条	0 条

三点结论：

1. **flash 裁判系统性宽松**：全部答案仅 1 处判 0（99.0%），区分度为零，对要点是否”推算正确”几乎不核验。
2. **plus 裁判系统性保守且不稳**：S003 single 直接把推理层/决策层打成 0/5、0/6（同一答法规则裁判判近满分），同一裁判对同一场景两种配置差 12 分，方差过大。
3. **kappa≈0**：两个 LLM 裁判的意见相关性接近随机。**结论：LLM 当 checklist 裁判不可靠，不能单独作为正式分数。** 本基准正式口径因此定为：三裁判多数票（2-of-3）为主指标、规则打分作零成本参照、投稿前由标注人对分歧项人工裁定（A6）。

这一发现与 LLM-as-a-judge 文献中”自偏好 / 评分分布偏移”现象一致，在中文灾害应急决策这一高后果场景中表现得更极端；它同时构成第 5 节约束校验组件的直接动机。

v0.4 全量（6 配置）裁判一致性 + A7 自一致

v0.4 全量上，flash 与 plus 两裁判在各配置下的 Cohen’s kappa 如下：

配置（被测模型 flash 或 plus）	Cohen’s kappa（flash vs plus）
multi@glm-4-flash	0.081
single@glm-4-flash	0.079
multi@glm-4-plus	−0.003

配置（被测模型 flash 或 plus）	Cohen’s kappa（flash vs plus）
multi-noaudit@glm-4-flash	−0.008
multi-verify@glm-4-flash	−0.005
single@glm-4-plus	−0.008

A7 自一致测试（同一 flash 裁判对同一批答案重打一次）：

配置	flash 自一致率
single@glm-4-flash	0.99
multi@glm-4-flash	1.00

结论（全量复现）。 两个 LLM 裁判在灾害 checklist 打分上各自高度稳定（自一致率 0.99~1.00），但彼此一致性接近 0（kappa≈0）。这一”各自稳定、互不一致”的组合直接支持”LLM 裁判不可互换”的结论，也是三裁判多数票协议与第 5 节确定性校验组件的设计动机——既然两个 LLM 裁判无法互相替代，就必须以 2-of-3 多数票汇总，并把最易出错的核对工作交给确定性规则。

A6 标注人终审裁定（8 场景 71 项真实三裁判分歧）

按 A6 路线抽检 multi@glm-4-flash 的 8 个场景（S002/S004/S005/S008/S015/S016/S018/S024，覆盖单灾种、链式、信息矛盾三类），抽取三裁判判定不一致的 **71 条要点**做终审裁定：每条将情报原文、要点文本与被测最终报告交由 glm-4-plus 以终审口径独立裁定（0/1+理由）生成机审底稿，再由标注人逐条复核确认。结果：

终裁 vs	一致率

终裁 vs	一致率
flash 裁判	**88.7%**（63/71）
多数票	**78.9%**（56/71）
规则裁判	74.6%（53/71）
plus 裁判	15.5%（11/71）

分歧集内的判分分布也揭示了裁判倾向：flash 在 71 条中判 1 达 70 条（几乎全判 1），plus 判 0 达 67 条（仅 4 条判 1），规则判 1 58 条；终裁本身判 1 为 64 条、判 0 为 7 条。

三点发现：

1. **plus 裁判在分歧集上严重偏向判 0**（71 条中 67 条判 0、仅 4 条判 1，与终裁一致率仅 15.5%），证实其”宁严勿松”是系统性假阴性而非”更严格更可靠”；它作为单一裁判完全不可用。
2. **flash 裁判与标注人终裁的一致率最高（88.7%）**，且 A7 显示其自一致率 0.99~1.00——flash 在本基准上”稳定且偏宽松”，在多数分歧项上恰与人类口径一致。
3. **多数票相对终裁存在可分解的误差**（与终裁不一致 15/71 = 21.1%）：其中 9 条为假阴性（flash 单票判 1 被规则与 plus 两票判 0 压掉）、6 条为假阳性（规则+flash 双判 1 而终裁认为未满足）。多数票协议的价值在于**稳健聚合**（防单裁判饱和/保守极值），其精度上限受最弱一票（plus）拖累；这也部分解释了为何多数票口径下 RQ1 的增益幅度有限。

综上：正式口径继续采用多数票，同时在论文与数据发布中公开全部逐条裁定底稿（results/adjudication-resolved.md），标注人终审结果作为人-机一致率的参照（分歧集上人-机一致率：vs 多数票 78.9%、vs flash 88.7%）。

6.6 RQ4：确定性约束校验能否替代/纠正 LLM 核对？（v0.4 全量，glm-4-flash，多数票口径）

§6.5 表明 LLM 裁判在”核对”上不可靠；§5 的 Verifier 正是冲着”最容易出错的核对工作”设计的。v0.4 全量上实现 V1~V5 模块后，在 multi 的审核官收口前接入违规清单（配置 **multi-verify**），与完整 multi 对照：

对比	场景级均值差	McNemar（b / c）	Wilcoxon	自助法 95% CI
multi-verify vs multi	**+2.81 pp**（verify 更高；综合 93.5% vs 90.7%）	b=10、c=30，**p=0.0027**	**p=0.0298**	**[+0.07, +6.10] pp**

（McNemar 表义：verify 对而 multi 错的要点 30 条，verify 错而 multi 对的要点 10 条。）

Verifier 确定性交叉统计（三配置对照，规则检出）：

配置	推算合规	资源超配违规	陷阱	运力缺口
multi@glm-4-flash	12/49	50	6	1
multi-verify@glm-4-flash	12/49	46	0	0
multi-noaudit@glm-	0/49	8	6	1

配置	推算合规	资源超配违规	陷阱	运力缺口
4-flash				

结论。 接入 Verifier 后 multi 在多数票口径下再提升 2.81pp（$p=2.7\times10^{-3}$，CI [+0.07, +6.10] pp 不含 0；综合得分 93.5% vs 90.7%），方向明确且显著。确定性检出显示：Verifier 主要压住**资源超配 / 陷阱 / 运力**类错误——陷阱 6→0、运力缺口 1→0 归零，资源超配在错误类型学口径下由 multi 的 7 条降至 multi-verify 的 0 条（§7.2）；而”推算合规”在 multi 与 multi-verify 中同为 12/49（noaudit 仅 0/49），说明**数值推算类要点仍由模型能力决定**，确定性规则负责核算、无法替模型把数字算出来。与 §6.5 中 kappa≈0 的 LLM 裁判形成对照：同一答案上 Verifier 重复运行输出恒定，天然解决裁判方差问题（对照设计见 §5.4）。

6.7 A2：双模型对照（glm-4-plus，接近天花板）

第二被测模型 glm-4-plus（同 API 的更强模型）在 v0.4 全量上表现接近天花板。先看 plus 自身的 multi vs single：

对比	场景级均值差	McNemar	自助法 95% CI
multi vs single（均 @glm-4-plus）	0.01 pp	二项精确 **p=1.0**	[−0.40, +0.44] pp

再看模型间对比（multi 配置）：

对比	场景级均值差	McNemar	Wilcoxon	自助法 95% CI
plus vs flash（均 multi 配置）	**+9.11 pp**（plus 更高）	**$p=2.05\times10^{-15}$**（plus 对而 flash 错 65	p≈0	[+6.11, +12.57] pp

对比	场景级均值差	McNemar	Wilcoxon	自助法 95% CI
		条、flash 对而 plus 错 0 条）		

满分场景统计（多数票口径）：single@plus 36 场景中 **35 个满分**（唯一非满分 S031 95.2%）；multi@plus 亦 **35 个满分**（唯一非满分 S009 94.7%）。

讨论。 plus 在本基准接近天花板：比 flash 高 9.11pp（$p=2.05\times10^{-15}$），且 multi 与 single 已无显著差异（均值差 0.01pp，CI [−0.40, +0.44] pp 跨 0，McNemar 二项精确 p=1.0）。这提示 CrisisBench v0.4 对强模型的区分度正在饱和：§7.2 中 plus 两配置除”数值推算失败”各 1 条外，其余错误类型全为 0；两个非满分场景也都只差 1 个要点。**建议 v0.5 增加更难场景，或改用”硬要点子集”（数值推算 / 矛盾 / 陷阱）作为更有区分度的指标。**

6.8 A8：成本与延迟（v0.4 全量实测）

在大规模部署前必须回答”多智能体不是白贵的”。下表报告六配置在三裁判多数票协议口径下的实测 API 成本（数据源为结果文件记录的 usage 字段，无估算；「主运行」含被测智能体推演调用与 1 次同侧裁判调用，「plus 裁判」为正式口径所需的第二次 LLM 裁判；A7 自一致复核为额外的稳定性实验，不计入协议成本）：

配置	被测模型	调用/场景	token/场景	耗时(s)/场景	全量 token	相对 token
single（单研判员）	glm-4-flash	3.0	5,829	73.4	209,842	1.00
multi（四角色	glm-4-flash	6.0	10,823	150.8	389,617	1.86

配置	被测模型	调用/场景	token/场景	耗时(s)/场景	全量token	相对token
串行）						
multi-noaudit（去审核官）	glm-4-flash	5.1	8,179	106.5	294,447	1.40
multi-verify（+约束校验）	glm-4-flash	6.0	11,098	145.5	399,537	1.90
single（单研判员）	glm-4-plus	3.0	8,173	66.6	294,245	1.40
multi（四角色串行）	glm-4-plus	6.0	15,956	104.9	574,419	2.74

结论。 多智能体带来可观但可控的成本：multi 的 token 约为 single 的 **1.86 倍**、调用数 2.0 倍、耗时约 2.06 倍，而场景级得分提升 7.05pp（§6.3）——即约 0.86 倍额外 token 换得 7.05pp 的决策质量增益。约束校验组件为零 API 调用（纯确定性规则），把 token 从 multi 的 10,823 微升至 11,098（+2.5%，源于注入违规清单与修正指令的提示词增量），却带来 2.81pp 增益并消除资源/陷阱类错误，单位成本性价比高于再加一个 LLM 角色。审核官消融（multi-noaudit）token 降至 multi 的 0.75 倍，但得分回落 7.32pp——**审核官是”便宜且关键”的一环**。更强模型 glm-4-plus 使 token 再升约 1.47 倍（multi@plus 574k vs multi@flash 390k）却已接近天花板（§6.7），提示单靠换大模型边际收益递减。完整成本明细（分运行单元）见 `crisis-bench/results/RESULTS-cost.md`；成本-得分散点见图 5

（crisis-bench/figures/fig5_cost.png）。费用未按厂商价目表折算（各 API 定价不同），正式版补录。

---

7 分析：错误类型学

7.1 试点样例：区分度来自硬要点

两个及以上裁判同时判 0 的”硬要点”清单（试点，96 要点）：

配置	场景-要点	内容	票型(规则/flash/plus)
两配置一致	S004-F9	推算苯蒸气到达居民区时间（2km÷4m/s≈8-9 分钟）	**0/0/0**
两配置一致	S001-F8	推算需转移留守人员规模（240 户≈300-500 人）	0/1/0
single（multi 下被修复）	S003-F8	推算火头抵近村庄时间（6km÷1-1.5km/h≈4-6 小时）	0/1/0
两配置一致	S005-R1	对矛盾数据采信保守口径并安排核灾	0/1/0
multi	S005-R2	冲锋舟运力缺口（2 艘×10 人/趟	0/1/0

配置	场景-要点	内容	票型(规则/flash/plus)
		vs 180 人）需增援	
single	S001-D4	帐篷缺口安置方案（12 顶不足→公共建筑集中安置）	0/1/0
single	S004-D4	邻近储罐喷淋冷却、消除火源	0/1/0
single	S002-D5	明确抢险优先级次序	0/1/0

解读：

1. **计算型/核算型要点命中率最低**，其中 S004-F9 三裁判全票 0——“从多条情报推算一个数字”是当前模型最稳定的失分点，也是本基准区分度的核心来源；
2. **multi 修好了两个 single 拿不到的点**：S003-F8（审核官补上 4-6 小时推算）与 S005-R2（运力缺口）——多智能体串行对”遗漏型错误”有补全效应，这是 multi > single 的具体证据链；
3. **矛盾口径（S005-R1）两种配置都没拿全**——对矛盾数据采信保守口径并安排核灾是稳定的区分点；
4. 陷阱型要点（帐篷缺口、邻近储罐冷却、优先级次序）只在 single 下失分，multi 的审核环节对”资源约束类”陷阱有纠正作用。

全量口径下各类”硬要点”在不同配置下的区分度见图 4（`crisis-bench/figures/fig4_hardpoints.png`）。

7.2 八类错误类型学（A9 定量统计，v0.4 全量，多数票口径失分要点计数）

沿用路线图 A9 的八类错误（定义与试点样例见下表），v0.4 全量六配置的失分要点计数如下：

#	错误类型	定义	试点样例（96 要点）
1	事实丢失	关键情报要素未捡全	试点事实层接近满分、未见稳定失分样例（v0.4 定量见下）
2	数值推算失败	推算型要点未推算/越界	S004-F9、S001-F8、S003-F8
3	资源超配	动用清单外资源或运力/容量不足	S005-R2（运力缺口）、S001-D4（帐篷容量不足）
4	情报冲突	建议与已确认事实矛盾	S005-R1（对矛盾数据未保守处置并核灾）
5	陷阱未识破	未识破并纠正错误做法	S004 水冲稀释（对应 V5）；S001-D4 帐篷缺口陷阱
6	笼统决策	只给原则不给具体对象+动作	S002-D5（优先级次序）待拆分归类

#	错误类型	定义	试点样例（96 要点）
7	对象缺失	措施无具体对象	试点未见稳定样例（v0.4 全为 0，对应 V6）
8	矛盾处理失当	矛盾口径未统一、未逐点上报	S005-R1 对应的矛盾处理维度

全量失分要点计数（多数票口径，36 场景）：

错误类	multi@flash	single@flash	multi-noaudit@flash	multi-verify@flash	multi@plus	single@plus
事实丢失	0	9	19	0	0	0
数值推算失败	28	35	39	26	1	1
资源超配	7	8	2	0	0	0
情报冲突	0	0	0	0	0	0
陷阱未识破	4	6	5	3	0	0
笼统决策	0	0	0	0	0	0
对象	0	0	0	0	0	0

错误类	multi@flash	single@flash	multi-noaudit@flash	multi-verify@flash	multi@plus	single@plus
缺失						
矛盾处理失当	10	16	13	6	0	0
推理缺失(其他)	7	8	20	4	0	0
决策未达标(其他)	10	35	19	7	0	0
失分要点合计	**66**	**117**	**117**	**46**	**1**	**1**

核心发现：

1. **数值推算型要点是最大失误源**：multi 28、single 35、noaudit 39 条；Verifier 也只能把 multi 的 28 压到 26——确定性规则能核算，但不能替模型推算。
2. **矛盾处理失当是持续高发的第二类失误**：single 16、multi 10、noaudit 13 条。
3. **审核官缺失（noaudit）带来”事实丢失→推理缺失→决策未达标”链条性恶化**（对比 multi）：事实丢失 0→19、推理缺失 7→20、决策未达标 10→19。
4. **Verifier 大幅压低资源类与陷阱类错误**（对比 multi）：资源超配 7→0 归零、陷阱未识破 4→3；总失分从 multi 的 66 条降至 46 条。

该类型学既是对被测系统的错误画像，也作为约束校验组件（§5）规则覆盖面的核对清单：V1~V5 分别锚定资源超配、数量核算、数值推算、情报冲突、陷

阱五类，与错误类型 2/3/4/5 一一对应；类型 6/7（笼统决策、对象缺失）由半自动 V6 处理；类型 1/8 依赖情报捡全与矛盾上报，现阶段主要靠 checklist 与人工抽检兜底。（错误类型学分布以本表为准，未单独出图——如需可视化可复用图 2 热图。）

---

8 局限与伦理

局限（投稿前必须如实保留并逐步消除）：

1. **部分实测仍未闭合。** 本文报告的实验数字来自 v0.3 试点（96 要点）与 v0.4 全量（36 场景、6 配置、709 要点、三裁判多数票口径），已含 A2/A3/A4/A5/A6/A7/A8/A9；但 A6 的终审裁定为”机审底稿 + 标注人复核”模式（71 项分歧底稿随数据发布，复核须在投稿前闭合）、A10 人类基线为可选未完成项；且 glm-4-plus 已接近天花板、区分度趋饱和，有待 v0.5 扩充更难场景。
2. **标注与要点初稿由 AI 助手代拟**，A6 分歧项终审底稿亦为机审生成——**投稿前由本人逐条审改并确认裁定**（见文末附记）。
3. **约束校验组件覆盖面有限。** V1~V5 已实现并在 v0.4 全量上验证（§6.6），但误报/漏报率未单独量化；陷阱（V5）与对象完整性（V6）仍依赖关键词/词表与半自动初审，覆盖面非完备——数值推算类要点仍由模型能力决定（multi 与 multi-verify 推算合规同为 12/49）。
4. **成本统计口径待统一。** A8 已实测 API 调用数、token 与耗时（§6.8），但 single@glm-4-flash 主运行期的 token 统计功能尚未上线，该配置的生成成本用同提示词独立复跑实测近似；费用未按厂商价目表折算（各 API 定价不同），正式版补录。

伦理声明。 ① 数据集全部为人工虚构场景，不含任何真实个人信息与真实警情；② 本工作面向辅助决策研究，结论不构成现场处置依据，不替代人防指挥；

③ 评审期拟以匿名形式在 Zenodo（CC-BY-4.0）与 HuggingFace 数据卡发布数据与代码（遵循 ARR 政策）；④ 初稿由 AI 助手代拟的事实已在文末附记声明，提交前须由本人逐条审改。

---

9 结论

本文提出了首个中文灾害多智能体决策评测基准 CrisisBench。数据集升级至 v0.4（36 场景、709 要点、48 条数值推算型要点，单灾种/链式/信息矛盾三类、8 类灾种），并配套三层 checklist 标注与三裁判多数票评测协议。综合 v0.3 试点（96 要点）与 v0.4 全量（6 配置）结果，实验证明：四角色串行多智能体稳定优于单智能体（v0.3 多数票 +5.2pp、严格口径 +20.9pp；v0.4 全量 +7.05pp、$p=3.0\times10^{-9}$）；审核官是增益的关键来源（消融回落 7.32pp、$p=6.5\times10^{-7}$）；约束校验组件再带来 2.81pp 增益（$p=2.7\times10^{-3}$），并把资源超配、陷阱、运力缺口类错误压至近零；LLM 裁判在灾害决策场景中不可互换（kappa≈0、自一致率 0.99~1.00），多数票与确定性校验是必要的补救；区分度集中于数值推算型要点这一最大失误源。更强模型 glm-4-plus 已接近天花板（较 flash 高 9.11pp、36 场景 35 个满分），提示基准需向更难场景与”硬要点子集”演进。A6 人工裁定（8 场景 71 项真实分歧，vs flash 一致 88.7%）与 A8 成本延迟统计（multi 约 1.86 倍 token）已完成。下一步按实验路线（§6.1）推进：A10 人类基线与 v0.5 难度扩充 → 英文改写并投稿。

参考文献（依据领域综述整理，正式投稿前逐条补全卷期页码）

1. Yao et al. ReAct: Synergizing Reasoning and Acting in Language Models.（07）
2. Wu et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. COLM 2024.（08）
3. 危机推文鲁棒性评测（6 个 LLM / 7.7 万条推文 / 洪水 • 求助 • 错别字三类软肋）. WWW 2025.（09）

4. 时空 KGQA 框架（联合时空嵌入与约束过滤）.（12）
5. CogMG：知识缺口捕获→补全→审核→写回的问答知识闭环.（14）
6. 多智能体综述（环境接口/角色画像/通信/能力习得）. IJCAI 2024.（41）
7. MetaAgent：设计者 LLM 自动生成最少必要智能体与有限状态机控制流.（42）
8. VeriMAP: Verification-Aware Planning for Multi-Agent Systems（Planner 拆解 DAG + 每子任务可执行验证函数）. arXiv:2510.17109.（52）
9. PMC: Planning with Multi-Constraints via Collaborative Language Agents（多约束任务的有向子任务图与约束改写）. COLING 2025, arXiv:2405.16510.（50）
10. E-KELL: Enhancing Emergency Decision-Making with Knowledge Graphs and Large Language Models（危化品泄漏应急决策支持，专家评分量化改进）. IJDRR 2024, Vol. 113: 104804.（05）
11. Sim911：LLM 扮演 911 调度员的培训模拟与评测. AAAI 2025.（63）
12. LogiDebrief：STL 时序逻辑 + LLM 的演练复盘自动判定. IJCAI 2025.（62）
13. DisasterTD：灾害图像地名消歧/落图（MLLM 候选 + 跨视角视觉裁决）.（60）
14. RescueADI：自适应灾害解读智能体（检测/分割/VQA 按需调度）.（61）
15. Edge et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130.（11）

说明：括号内编号为综述 `domain-review.md` 中的编号；正式稿将替换为完整文献条目（作者/卷期/DOI）。 全部条目已于 2026-10-18 经 WebSearch 逐条核实（见 `crisis-bench/references-verified.md`）；待并入正式列表的已核实条目：LLM-as-a-judge（Zheng et al., MT-Bench, NeurIPS 2023 D&B）、HELM（Liang et al., TMLR 2023）、BIG-bench、AgentBench（ICLR 2024）、AutoGen（COLM 2024，已列第 2 条）、ReAct（ICLR 2023）、RAG（NeurIPS 2020）、CogMG

（arXiv:2406.17231）、MetaAgent（ICML 2025）、LEGOMem（arXiv:2510.04851）、Sim911（arXiv:2412.16844）、LogiDebrief（arXiv:2505.03985）、危机推文评测（WWW 2025, DOI:10.1145/3696410.3714511）、RescueADI（arXiv:2410.13384）。

初稿 v3 完（2026-10-19）。下一版待办：A6 终裁底稿的标注人逐条复核、A8 成本延迟、A10 人类基线、v0.5 难度扩充、参考文献规范化、摘要英文版。

附记（编务说明：不随投稿正文提交，投稿清样时整段删除）

重要声明（投稿红线，务必保留）：本文初稿由 AI 助手基于已完成的实验与文献综述代拟；投稿或提交考核前必须由本人（徐向阳）逐条审改，特别是：场景标注（scenarios.json 全部要点）、实验结论的表述、参考文献条目。所有数字均引自 v0.3 实验结果（`research/crisis-bench/results/RESULTS.md` 与 `results/*.json`）与 v0.4 场景表（`crisis-bench/scenarios/rubric.md` §五），未编造。