面向灾害态势推理与辅助决策的多智能体评测：

CrisisBench 基准与约束校验

论文初稿 v0.1（2026-10-18）

重要声明（投稿红线，务必保留）：本文初稿由 AI 助手基于已完成的实验与文献综述代拟；投稿或提交考核前必须由本人（徐向阳）逐条审改，特别是：场景标注（scenarios.json 全部要点）、实验结论的表述、参考文献条目。所有数字均引自 `research/crisis-bench/results/RESULTS.md` 与 `results/*.json`，未编造。

配套材料：领域综述 · 路线图 · 评分细则 · 实验结果

摘要

大语言模型（LLM）驱动的多智能体协作已在办公、代码等开放域任务中展现出组织优势，但在灾害应急决策这一高后果领域，目前既缺乏评测多智能体决策质量的基准，也缺少对决策输出进行可信校验的机制。本文提出 CrisisBench——一个中文灾害态势推理与辅助决策评测基准，并配套设计约束校验组件。CrisisBench 包含 5 个灾害场景（地震、洪涝、山火、化工泄漏、台风，覆盖单灾种、链式次生灾害与信息矛盾三类难度），共 96 个评分要点，按事实层、推理层、决策层三层组织，采用 checklist 式 0/1 客观判定。为防止智能体直接抄录情报获得满分，每个场景嵌入数值推算型要点（关键数字必须跨多条情报计算得出）与陷阱型、矛盾型要点。基于 glm-4-flash 的全量实验表明：（1）多智能体（四角色串行）在三裁判多数票口径下较单智能体提升 5.2 个百分点（95.8% vs 90.6%），在更严格的裁判口径下提升 20.9 个百分点；（2）两个 LLM 裁判之间的 Cohen's kappa 仅为 0.03~0.08，证明 LLM 作为 checklist 裁判在灾害决策场景中不可互换,多数票（2-of-3）协议是可行的替代口径；（3）区分度集中于 4 个数值推算型要点等"硬要点"，其中苯蒸气扩散时间推算在三种裁判口径下全部为 0 命中，是当前模型最稳定的失分点。针对 LLM 裁判不可靠的问题，本文设计了约束校验组件（资源超配审计、数量核算、数值推算核对、情报冲突检查、陷阱处置识别五类确定性规则），并给出与 LLM 裁判的对照实验方案。本文的贡献是一个可复现的中

文灾害多智能体决策基准、一套三裁判多数票评测协议，以及一项以确定性规则替代 LLM 裁判的组件设计。

关键词：灾害应急决策；多智能体；评测基准；大语言模型；约束校验；三层评分

1 引言

灾害发生后，指挥机构面临海量异质信息（现场报告、社交媒体、气象水文、遥测数据）与极强的时效压力，需要在信息残缺、甚至互相矛盾的条件下快速形成"现在什么情况、下一步会怎么样、该怎么办"的研判结论。大语言模型与多智能体协作框架为此提供了新工具：多个角色各司其职、互相校验，有望将碎片信息组织成可追溯的决策建议。

但这一方向缺少一个基本的评测基础设施。文献调研显示，已有工作分散在四个孤立位置：灾害信息入口（推文分类、地名落图）、灾害知识问答（以知识图谱增强 LLM）、多智能体协作机制（集中在办公、代码、旅行规划域）、以及灾害领域落地（培训模拟 Sim911 测的是"话务员表现"而非"决策质量"，复盘评估 LogiDebrief 做的是事后分析而非事中决策）。**没有人建立过"多智能体灾害态势推理与辅助决策"的决策质量评测基准**——多智能体在灾害决策中究竟是帮推理、还是害事实，知识增强与校验机制在哪里起作用，均缺乏可测量、可复现的证据。与此同时，灾害决策的约束（资源守恒、空间一致性、时序合法性）天然可形式化，却还没有被做成智能体输出之前的"验收关卡"。

针对上述空白，本文做三件事：

1. **构建 CrisisBench 基准**：5 个中文灾害决策场景、96 个评分要点，采用"事实层 / 推理层 / 决策层"三层标注；场景设计刻意嵌入数值推算型要点、矛盾情报与陷阱处置诱导，防止"抄情报即满分"，保证区分度。
2. **提出三裁判多数票评测协议**：同一批答案分别由规则匹配器与两个 LLM 裁判独立打分，以 2-of-3 多数票为正式口径，并强制报告裁判间一致率与 Cohen's kappa。实验中最直接的发现——两个 LLM 裁判 kappa≈0——本身就是方法论文献中 LLM-as-a-judge 不可靠性在灾害决策场景的一次实证。
3. **设计约束校验组件**：把资源超配、数量核算、数值推算、情报冲突、陷阱处置五类检查写成确定性规则，作为决策链的验收关卡，并给出其与 LLM 裁判的

对照实验设计。动机直接来自裁判可靠性实验：最容易出错的核对工作应当交给确定性规则而非 LLM。

主要实验发现（被测模型 glm-4-flash，96 要点 × 2 配置 × 3 裁判）：

- 多智能体（情报官→研判官→决策官→审核官串行）优于单智能体：多数票口径 +5.2pp，严格裁判口径 +20.9pp；
- LLM 裁判不可靠：宽松裁判模型接近饱和（99.0% 全对），严格裁判模型系统性收紧且方差大（同一场景同一批答案差 12 分），两者 kappa≈0；
- 区分度来自"硬要点"：4 个数值推算型要点是全部配置的失分点，其中"推算苯蒸气到达居民区时间"三种裁判全票 0；多智能体的增益来自审核环节对"遗漏型错误"的补全（修复 2 个单智能体拿不到的计算型要点）。

2 相关工作

本节按"灾害信息入口 → 知识增强推理 → 多智能体协作 → 灾害领域落地"四个链段简述与本工作最相关的研究（完整调研见配套综述）。

灾害信息入口。 从碎片信息到结构化要素是决策的前置环节。早期监督分类模型依赖标注且跨灾种泛化差；近期工作系统评测了 LLM 零样本分类在危机推文上的表现，发现其仍低于监督基线，且洪水类别、求助类信息、错别字文本是三类显著软肋 [危机推文评测, WWW'25]。地名落图与遥感综合解读等工作把 LLM 感知能力推进到定位层面 [DisasterTD; RescueADI]，但都止步于感知层，未进入决策层。

知识增强推理。 KG 增强 LLM、GraphRAG、闭环自修正与时序演化是该链段的发展主线 [RAG; E-KELL; GraphRAG 综述; CogMG; 时空 KGQA]。代表性的灾害领域工作是 E-KELL：将历史灾害事件三元组构成知识图谱供 LLM 查询，问答 F1 从 59.31% 提升至 65.63%，但其形态是静态问答，对冷门领域问题会拒答，且并非多智能体结构。通用知识增强技术已相当成熟，"拼装"难度不大；空白在于灾害领域的定制（因果链表示、时空约束与决策挂钩）与评测。

多智能体协作。 从 ReAct 的单智能体"想一步做一步"，到 AutoGen 的对话式多角色协作、自动编排与成本调度、以及带验证函数与程序性记忆的闭环框架 [ReAct; AutoGen; MetaAgent; VERIMAP; LEGOMem; PMC]，协作范式已经由"提示词工程"变成"系统工程"：状态机、验证函数、记忆库齐备。**但这些机制的评测全部位于数学、代码、旅行、**

办公域，没有一项针对灾害决策的独特约束（致命后果、时间压力、信息残缺、链式次生灾害）进行过建模与评测。

灾害领域落地。 已有四个分散的脚印：Sim911 用 LLM 扮演 911 调度员做培训模拟，其评测口径是学员表现而非系统决策质量 [Sim911, AAAI'25]；LogiDebrief 把演练复盘需求转成时序逻辑公式自动判定，属于事后评估 [LogiDebrief, IJCAI'25]；E-KELL 面向问答；DisasterTD/RescueADI 面向感知。"多智能体协作研判决策"这一段是空的——本文的 CrisisBench 正是填补这一空白，而约束校验组件则承接 VERIMAP"每子任务配可执行验证函数"的思路，将其灾害化：把资源守恒、数值推算、情报一致性写成验收规则。

3 CrisisBench 基准设计

3.1 场景设计

每个场景定义为五元组：(灾种，时间点，情报片段，可用资源清单，三层评分要点)。情报片段 9~11 条，其中刻意混入：**干扰情报**（与决策无关但易诱导展开，如"邻县消防大队刚完成演练"）、**矛盾情报**（同一指标出现冲突口径）、**错误处置诱导**（如"有人提议用消防水带直接冲洗地面苯液"）。资源清单显式列出可调用资源与"无"项（如"无直升机"），用于资源超配陷阱。

v0.3 版共 5 个场景、96 个要点，覆盖三类难度：

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
S001	地震	链式次生灾害	震后 5 小时	8/4/6 = 18	撤离规模需推算（240 户×1-2 人）；帐篷缺口陷阱；土木房余震风险

S002	洪涝	单灾种	特大暴雨第 2 天	8/4/6 = 18	被困总数汇总（约 200 人）；医院 4 小时保电窗口；私家车乱入
S003	山火	单灾种	火起第 3 小时	8/5/6 = 19	火头到达时间推算（4-6 小时）；夜间降温≠火势减弱；村民上山
S004	化工泄漏	链式次生灾害	泄漏发生 1 小时	9/5/7 = 21	苯蒸气 8-9 分钟到达推算；水冲稀释陷阱；邻近储罐次生爆炸
S005	台风	信息矛盾	灾中	8/5/7 = 20	三组数据矛盾；冲锋舟 2 艘 vs 8 艘运力缺口；调头传言

场景以中文撰写，素材原型取自公开灾害调查报告与通报中的典型要素（水库裂缝、隧道被困、隔离带缺失、泄漏入河等），投稿前由标注人逐条复核其合理性。

3.2 三层评分细则（checklist 式客观判定）

所有要点按三层组织，**每个要点独立判 0/1，不存在 0.5 分**，且"采点不算错点"——只检查"该说的说了没有"，不惩罚无关内容（决策层出现硬伤除外）。判定采用 checklist 式，同义替换（"撤离"="疏散"）算命中。

- **事实层（F）**：回答是否捡全关键情报要素。**数值推算型要点**（v0.3 新增，要点注明"推算"）：关键数字不直接出现在情报里，回答必须给出**推算出的数值或数值区间**才算满足；只复述情报里的原始数字不算。裁判对照情报原文核验数值。
- **推理层（R）**：判定对象是**结论**——回答明确表达出该条目结论（措辞可不同、意思到位、不与情报矛盾）得 1；结论未出现或相反得 0。场景 JSON 中保

留的"起点/机制/终点"字段仅供人工核对与论文展示因果结构，不作为裁判逐字对号要求（v0.2 经验：逐字对号会使裁判方差爆炸）。

- **决策层（D）**：每条建议**有具体对象 + 具体动作**得 1；笼统表述（"加强力量""做好工作"）得 0。出现下列任一硬伤，该条不得分并记录原因：① 无对象（"立即撤离"但未指明村庄/人群）；② **资源超配**（动用资源清单之外的资源，如 S001 无直升机却"派直升机巡查"）；③ 与情报冲突（如道路已断仍"通过县道撤离"且未提绕行）。陷阱型要点以"必须识破错误做法"的方式表述，识破并给出正确做法才得分。

三层得分均为命中数/要点数，综合得分取三层等权平均仅作总览排序用；论文正文以分层结果为主。

3.3 要点设计要求与两次校准

基准构建过程保留了两次校准记录（数据文件随基准公开），这本身构成论文"基准构建方法论"部分：

- **v0.2 教训一：事实层满分无区分度。** 情报直接送达被测智能体，事实要点几乎都能抄到，全配置接近满分。→ v0.3 为每个场景新增 1~2 条**数值推算型要点**：要求跨 2~3 条情报推算（如"两村共约 240 户、每户留守 1 至 2 人"→ 约 300~500 人；"火线距村 6 公里、蔓延时速 1~1.5 公里"→ 约 4~6 小时抵近；"距居民区 2 公里、风速 4 米/秒"→ 约 8~9 分钟到达）。
- **v0.2 教训二：裁判方差过大。** 同一批回答，glm-4-flash 原提示词几乎全判 1，glm-4-plus 加"宁严勿松"提示词后推理/决策层几乎全判 0。→ v0.3 双管齐下：① 要点全部改写为**可客观核验的具体结论/具体措施**（不再考"链条写没写全"这类模糊项）；② 裁判提示词取中间口径，并保留双模型交叉裁判。

3.4 评测协议：三裁判多数票 + 可靠性强制报告

打分实现分两种：

1. **规则打分（零成本参照）**：逐要点关键词匹配，命中词表即得 1。免费、零波动，但"提到词≠答对"，定位为开发自检与廉价参照，不作为正式分数。
2. **LLM 打分（正式）**：把"情报原文 + 要点清单（唯一编号）+ 被测回答"交给裁判模型，要求逐条输出 JSON 的 0/1 与一句理由；要点注明"推算"的必须核对数

值；裁判漏判按 0 分计；解析失败重试一次。裁判与被测模型同 API 但独立调用、角色隔离，且裁判温度设为 0。

协议三个要点（对应论文"评测协议"章节）：

- **多裁判多数票**：每个要点由规则 + glm-4-flash + glm-4-plus 三方独立判定，**2-of-3 多数票为正式主指标**；
- **同批答案换裁判重打分（--rescore）**：保证"分数之差 = 裁判之差、与答案无关"，是裁判可靠性分析的必要设计；
- **强制报告一致率与 kappa**：裁判两两一致率与 Cohen's kappa 必须随主结果一同报告（结果见 §4.4），并由标注人对分歧项人工抽检裁定（当前为待办项，投稿前完成）。

4 实验

4.1 实验设置

- **被测智能体**：glm-4-flash（温度 0.1）。两种配置：
  - **single**：单研判员一次性作答"事实要素/态势研判/行动建议"三部分；
  - **multi**：情报官→研判官→决策官→审核官四角色串行；除情报官外每个角色可见前面角色发言（公开对话、可追溯），**以审核官最终报告作为打分对象**。
- **裁判**：规则匹配器、glm-4-flash（温度 0）、glm-4-plus（温度 0）；同一批答案由两个 LLM 裁判各打一遍（rescore 机制）。
- **规模**：5 场景 × 2 配置 × 96 要点 × 3 裁判口径，共 12 份计分记录（含 v0.2 两轮校准证据）。
- **成本结构事实**：multi 每场景 4 次 API 调用（每角色一次）而 single 为 1 次，协作带来的调用开销为 4 倍（本次未采集耗时与 token 统计，正式版补录）。

4.2 主结果

配置	规则打分	flash 裁判	plus 裁判	三裁判多数票(2-of-3)
single（单研判员）	84/96 = **87.5%**	95/96 = 99.0%	56/96 = **58.3%**	87/96 = **90.6%**

multi（四角色串行）	89/96 = **92.7%**	95/96 = 99.0%	76/96 = **79.2%**	92/96 = **95.8%**
multi − single	**+5.2pp**	0（flash 裁判饱和）	**+20.9pp**	**+5.2pp**

分场景明细（命中/总数）：

场景	single 规则	single flash	single plus	multi 规则	multi flash	multi plus
S001 地震	14/18	18/18	14/18	17/18	18/18	17/18
S002 洪涝	17/18	18/18	10/18	18/18	18/18	16/18
S003 山火	18/19	19/19	7/19	17/19	19/19	19/19
S004 化工	19/21	20/21	11/21	20/21	20/21	9/21
S005 台风	16/20	20/20	14/20	17/20	20/20	15/20

4.3 多智能体 vs 单智能体

"multi > single" 在规则（+5.2pp）、plus（+20.9pp）、多数票（+5.2pp）三种口径下全部成立；仅在 flash 裁判口径下测不出差异，原因是该裁判已饱和（99.0%）。分层看：

- multi 的增益不是事实层（两种配置事实层都接近满分，恰是 v0.2 校准期的现象），而来自推理/决策层与个别硬要点（见 §4.5 的补全效应）；
- multi 的代价是 4 倍 API 调用与更长的推演链（结构事实，本次未计时）；
- 一个例外值得注意：S004 在 plus 裁判下 multi（9/21）反而低于 single（11/21），结合 §4.4 中 plus 裁判方差偏大的证据，该差异更多反映裁判波动而非配置真实差异——这正是多数票口径存在的意义。

4.4 裁判可靠性：三个裁判不可互换

同批答案、同一裁判提示词，flash 与 plus 逐条对比：

配置	一致率	Cohen's kappa	flash=1 且 plus=0	flash=0 且 plus=1
single	59.4%	**0.03**	39 条	0 条
multi	80.2%	**0.08**	19 条	0 条

三点结论：

1. **flash 裁判系统性宽松**：全部答案仅 1 处判 0（99.0%），区分度为零，对要点是否"推算正确"几乎不核验。
2. **plus 裁判系统性保守且不稳**：S003 single 直接把推理层/决策层打成 0/5、0/6（同一答法规则裁判判近满分），同一裁判对同一场景两种配置差 12 分，方差过大。
3. **kappa≈0**：两个 LLM 裁判的意见相关性接近随机。**结论：LLM 当 checklist 裁判不可靠，不能单独作为正式分数。** 本基准正式口径因此定为：三裁判多数票（2-of-3）为主指标、规则打分作零成本参照、投稿前由标注人对分歧项人工裁定。

这一发现与 LLM-as-a-judge 文献中"自偏好 / 评分分布偏移"现象一致，在中文灾害应急决策这一高后果场景中表现得更极端；它同时构成第 5 节约束校验组件的直接动机。

4.5 区分度来源：计算型要点与陷阱要点

两个及以上裁判同时判 0 的"硬要点"清单：

配置	场景-要点	内容	票型(规则/flash/plus)
两配置一致	S004-F9	推算苯蒸气到达居民区时间（2km÷4m/s≈8-9 分钟）	**0/0/0**
两配置一致	S001-F8	推算需转移留守人员规模（240 户≈300-500 人）	0/1/0
single（multi 下被修复）	S003-F8	推算火头抵近村庄时间（6km÷1-1.5km/h≈4-6 小时）	0/1/0
两配置一致	S005-R1	对矛盾数据采信保守口径并安排核灾	0/1/0
multi	S005-R2	冲锋舟运力缺口（2 艘×10 人/趟 vs 180 人）需增援	0/1/0

single	S001-D4	帐篷缺口安置方案（12 顶不足→公共建筑集中安置）	0/1/0
single	S004-D4	邻近储罐喷淋冷却、消除火源	0/1/0
single	S002-D5	明确抢险优先级次序	0/1/0

解读（论文错误分析的素材）：

1. **四个计算型要点命中率最低**，其中 S004-F9 三裁判全票 0——"从多条情报推算一个数字"是当前模型最稳定的失分点，也是本基准区分度的核心来源；
2. **multi 修好了两个 single 拿不到的点**：S003-F8（审核官补上 4-6 小时推算）与 S005-R2（运力缺口）——多智能体串行对"遗漏型错误"有补全效应，这是 multi > single 的具体证据链；
3. **矛盾口径（S005-R1）两种配置都没拿全**——对矛盾数据采信保守口径并安排核灾是稳定的区分点；
4. 陷阱型要点（帐篷缺口、邻近储罐冷却、优先级次序）只在 single 下失分，multi 的审核环节对"资源约束类"陷阱有纠正作用。

5 约束校验组件（设计）

5.1 动机

§4.4 表明：把 checklist 核对交给 LLM 裁判，代价是饱和、方差与近乎随机的裁判间一致性。而灾害决策中真正需要核对的许多事项——资源是否超配、数量是否对得上、推算数值是否正确、建议是否与已确认事实冲突——**天然是可形式化的确定性检查**。因此本工作设计一个确定性约束校验组件（VeriMap 灾害化），置于 multi 流水线中审核官之前：对前序发言（或最终报告）运行规则校验，输出违规清单，交由审核官修正后再出最终报告。组件不替代 LLM 裁判，而承担"最容易出错的核对工作"。

5.2 规则表

编号	类别	检查内容（确定性实现）	对应场景实例

V1	资源超配	决策中出现的每项资源必须属于场景资源清单，或附带"外部调援 + 来源"说明（清单显式列出"无直升机"等否定项）	S001 无直升机却调直升机；S005 按 8 艘冲锋舟部署（实际 2 艘）
V2	数量核算	按清单数量核算运力/安置容量是否满足决策目标规模（人数×趟数与船只数、帐篷数 vs 安置人数）	S005 2 艘×10 人/趟 vs 180 人；S001 帐篷 12 顶 vs 300-500 人
V3	数值推算核对	对注明"推算"的要点，从情报数值按公式计算期望区间，检查回答中的数值是否落入区间	S001-F8（240×1~2→300~500）；S003-F8（6km÷1~1.5km/h→4~6h）；S004-F9（2km÷4m/s→8~9min）
V4	情报冲突	决策中的断言（路线、对象、状态）与"已确认事实"集合（如道路中断）冲突则报错	S001 县道中断仍建议"经县道撤离"且未提绕行
V5	陷阱处置	识别错误处置表述并报错（关键词+词性模板，如"冲洗/稀释+化学品"）	S004 水带冲洗地面苯液；S002 放任私家车自发抽水；S003 村民无防护夜间上山
V6（半自动）	对象完整性	"撤离/救援"类措施必须带具体对象；确定性实现受限，由 LLM 初审 + 规则终审	全场景（模糊措施"做好工作"类）

5.3 伪代码

```
def verify(answer, scene) -> list[Issue]:
    issues = []
    for r in extract_resources(answer):                    # 实体抽取/词表匹配
        if r not in scene.资源 and not has_sourcing(answer, r):
```

```
            issues.append(Issue("V1 资源超配", r))
    for target, plan in scene.核算量():                      # 标注人预写的核对条目
        if capacity(plan) < target:                          # 2 艘×10 人/趟 vs 180 人
            issues.append(Issue("V2 运力缺口", target, plan))
    for key, (formula, interval) in scene.数值推算.items():   # 标注人预写的公式与区间
        val = extract_number(answer, key)
        if val is None or val not in interval:               # 未推算 或 越界
            issues.append(Issue("V3 推算缺失/越界", key, interval))
    for fact in scene.已确认事实:                             # 道路中断、坝体裂缝等
        if contradicts(answer, fact):
            issues.append(Issue("V4 情报冲突", fact))
    for pattern in scene.陷阱模式:                            # 冲洗+稀释+苯 类模板
        if pattern.matches(answer):
            issues.append(Issue("V5 陷阱处置", pattern))
    return issues
```

要点：**所有规则参数（公式、区间、资源清单、事实集、陷阱模板）由标注人在场景 JSON 中显式给出**，组件本身不含任何训练参数；同一答案运行任意次输出恒定，天然解决 §4.4 的裁判方差问题。

5.4 与 LLM 裁判的对照实验设计

- **RQ1（等价性）**：校验器对 8 条硬要点（§4.5）的判定与三裁判多数票的一致率；预期 V1~V4 完全覆盖计算型与资源型硬要点，V5/V6 为部分覆盖。
- **RQ2（增益）**：将违规清单注入 multi 流水线（审核官出报告前强制附载、要求逐条修正），对比 multi+verify 与 multi 的硬要点命中率与总命中率；预期修复 S004-F9、S005-R2 等规则可判要点。
- **RQ3（稳定性）**：同一批答案校验器运行 10 次输出完全一致；与 §4.4 中 kappa≈0 的 LLM 裁判形成对照，量化"确定性校验替代 LLM 核对"的可靠性收益。
- **RQ4（成本）**：校验器零 API 调用、毫秒级耗时，与 LLM 裁判每要点一次调用对比（正式版实验采集 token/耗时后报告）。

6 结论、局限与下一步

结论。 本文提出了首个中文灾害多智能体决策评测基准 CrisisBench（5 场景、96 要点、三层 checklist 标注、计算型/矛盾型/陷阱型要点设计），并给出三裁判多数票评测协议。实验证明：四角色串行多智能体在多口径下优于单智能体（多数票 +5.2pp）；LLM 裁

判在灾害决策场景中不可互换（kappa≈0），多数票与确定性校验是必要的补救；区分度集中于数值推算型要点，而多智能体的审核环节能补全"遗漏型"错误。

局限（投稿前必须如实保留并逐步消除）：

1. 场景规模小（5 个）、被测模型单一（glm-4-flash）——v0.4 扩展至 30~40 场景、2 个模型；
2. 场景标注与要点初稿由 AI 助手代拟，人工抽检与分歧裁定尚未完成——**投稿前由本人逐条审改**；
3. 约束校验组件目前是设计（规则表 + 伪代码），尚无实现与实验数据——§5.4 的 RQ1~RQ4 是近期实验计划；
4. 未采集 token/耗时成本数据——正式版补录。

下一步（按路线图）：实现约束校验组件并跑通 §5.4 对照实验 → 场景扩充与双模型全量 → 完成人工抽检与裁判分歧裁定 → 完善写作并投稿（目标期刊 IJDRR）。

参考文献（依据领域综述整理，正式投稿前逐条补全卷期页码）

1. Yao et al. ReAct: Synergizing Reasoning and Acting in Language Models.（07）
2. Wu et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. COLM 2024.（08）
3. 危机推文鲁棒性评测（6 个 LLM / 7.7 万条推文 / 洪水·求助·错别字三类软肋）. WWW 2025.（09）
4. 时空 KGQA 框架（联合时空嵌入与约束过滤）.（12）
5. CogMG：知识缺口捕获→补全→审核→写回的问答知识闭环.（14）
6. 多智能体综述（环境接口/角色画像/通信/能力习得）. IJCAI 2024.（41）
7. MetaAgent：设计者 LLM 自动生成最少必要智能体与有限状态机控制流.（42）
8. VERIMAP：Planner 拆解 DAG + 每子任务可执行验证函数.（52）
9. PMC：多约束任务的有向子任务图与约束改写.（50）
10. E-KELL：灾害事件知识图谱 + LLM 问答（F1 59.31%→65.63%）. IJDRR 2023.（05）
11. Sim911：LLM 扮演 911 调度员的培训模拟与评测. AAAI 2025.（63）
12. LogiDebrief：STL 时序逻辑 + LLM 的演练复盘自动判定. IJCAI 2025.（62）

13. DisasterTD：地名落图（MLLM 候选 + 跨视角视觉裁决）.（60）

14. RescueADI：自适应灾害解读智能体（检测/分割/VQA 按需调度）.（61）

15. GraphRAG 综述（建图索引→图引导检索→生成）.（11）

说明：括号内编号为综述 `domain-review.md` 中的编号；正式稿将替换为完整文献条目。

初稿完（2026-10-18）。下一版待办：C 组件实现与 RQ1~RQ4 实验数据、人工抽检结果、参考文献规范化、摘要英文版。