面向灾害态势推理与辅助决策的多智能体评测：CrisisBench 基准与约束校验

论文初稿 v3.2（2026-10-19：v0.4 全量结果 + A6 分歧项经标注人复核闭合 + A8 成本延迟并入） 配套材料：领域综述 · 路线图 · 评分细则 · 实验结果

摘要

大语言模型（LLM）驱动的多智能体协作已在办公、代码等开放域任务中展现出组织优势，但在灾害应急决策这一高后果领域，目前既缺乏评测多智能体决策质量的基准，也缺少对决策输出进行可信校验的机制。本文提出 CrisisBench——一个中文灾害态势推理与辅助决策评测基准，并配套设计约束校验组件。CrisisBench v0.4 包含 36 个灾害场景（单灾种 14、链式次生灾害 14、信息矛盾 8，覆盖地震、洪涝、山火、化工爆炸/泄漏、台风、泥石流、山洪、城市内涝、低温雨雪冰冻、暴雪、大风、中毒、粮库/民房火灾、水库泄洪、坍塌等 20 余类灾情），共 709 个评分要点，其中 48 条为数值推算型要点，按事实层、推理层、决策层三层组织，采用 checklist 式 0/1 客观判定。为防止智能体直接抄录情报获得满分，每个场景嵌入数值推算型要点（关键数字必须跨多条情报计算得出）与陷阱型、矛盾型要点。基于 glm-4-flash 的试点实验（其前身 v0.3 的 96 要点 × 2 配置 × 3 裁判）表明：（1）多智能体（四角色串行）在三裁判多数票口径下较单智能体提升 5.2 个百分点（95.8% vs 90.6%），在更严格的裁判口径下提升 20.9 个百分点；（2）两个 LLM 裁判之间的 Cohen’s kappa 仅为 0.03~0.08，证明 LLM 作为 checklist 裁判在灾害决策场景中不可互换，三裁判多数票（2-of-3）协议是可行的替代口径；（3）区分度集中于数值推算型要点等"硬要点"，其中苯蒸气扩散时间的推算在三种裁判口径下全部为 0 命中，是当前模型最稳定的失分点。随后，本文完成 v0.4 全量实验（36 场景、709 要点、6 配置、三裁判多数票口径），对上述发现做定量确认：多智能体较单智能体场景级得分高 7.20 个百分点（综合 90.5% vs 83.3%；$p=1.9\times10^{-9}$，95% CI [+3.4, +11.2] pp），与试点 +5.2pp 同量级；审核官消融使多智能体回落 7.04 pp（$p=1.8\times10^{-6}$）；约束校验组件再带来 2.81 pp 增益（$p=2.7\times10^{-3}$，95% CI [+0.1, +6.1] pp），并将资源超配、陷阱、运力缺口类错误压至近零；更强模型 glm-4-plus 较 flash 高 9.39 pp（$p=7.4\times10^{-16}$）、接近天花板；两 LLM 裁判 kappa≈0 而各自自一致率 0.99~1.00，坐实三裁判多数票协议与确定性校验的必要性。A6 人工裁定（8 场景 71 项真实三裁判分歧，经标注人复核后终裁 vs 多数票一致 90.1%、vs flash 80.3%，多数票高于任一单裁判）与 A8 成本延迟统计（multi 约为 single 的 1.86 倍 token）亦已完成。针对 LLM 裁判不可靠的问题，本文设计了约束校验组件（资源超配审计、数量核算、数值推算核对、情报冲突检查、陷阱

处置识别五类确定性规则），并在 v0.4 全量上与 LLM 裁判对照验证其有效性。本文的贡献是一个可复现的中文灾害多智能体决策基准、一套三裁判多数票评测协议，以及一个以确定性规则替代/纠正 LLM 裁判、并经全量验证有效的约束校验组件。

关键词：灾害应急决策；多智能体；评测基准；大语言模型；约束校验；三层评分

---

1 引言

灾害发生后，指挥机构面临海量异质信息（现场报告、社交媒体、气象水文、遥测数据）与极强的时效压力，需要在信息残缺、甚至互相矛盾的条件下快速形成"现在什么情况、下一步会怎么样、该怎么办"的研判结论。大语言模型与多智能体协作框架为此提供了新工具：多个角色各司其职、互相校验，有望将碎片信息组织成可追溯的决策建议。

但这一方向缺少一个基本的评测基础设施。文献调研显示，已有工作分散在四个孤立位置：灾害信息入口（推文分类、地名落图）、灾害知识问答（以知识图谱增强 LLM）、多智能体协作机制（集中在办公、代码、旅行规划域）、以及灾害领域落地（培训模拟 Sim911 测的是"话务员表现"而非"决策质量"，复盘评估 LogiDebrief 做的是事后分析而非事中决策）。**没有人建立过"多智能体灾害态势推理与辅助决策"的决策质量评测基准**——多智能体在灾害决策中究竟是帮推理、还是害事实，知识增强与校验机制在哪里起作用，均缺乏可测量、可复现的证据。与此同时，灾害决策的约束（资源守恒、空间一致性、时序合法性）天然可形式化，却还没有被做成智能体输出之前的"验收关卡"。

针对上述空白，本文做三件事：

1. **构建 CrisisBench 基准**：v0.4 版 36 个中文灾害决策场景（单灾种 14 / 链式次生灾害 14 / 信息矛盾 8）、共 709 个评分要点，采用"事实层 / 推理层 / 决策层"三层标注；场景设计刻意嵌入数值推算型要点（48 条）、矛盾情报与陷阱处置诱导，防止"抄情报即满分"，保证区分度。其前身 v0.3（5 场景、96 要点）已完成基准构建与校准，并作为本文试点实验（§6.3、§6.5）的数据基础。
2. **提出三裁判多数票评测协议**：同一批答案分别由规则匹配器与两个 LLM 裁判独立打分，以 2-of-3 多数票为正式口径，并强制报告裁判间一致率与 Cohen’s kappa。试点中最直接的发现——两个 LLM 裁判 kappa≈0——本身就是方法论文献中 LLM-as-a-judge 不可靠性在灾害决策场景的一次实证。
3. **设计约束校验组件**：把资源超配、数量核算、数值推算、情报冲突、陷阱处置五类检查写成确定性规则，作为决策链的验收关卡，并完成其与 LLM 裁判的对照实验（§6.6）。动机直接来自裁判可靠性实验：最容易出错的核对工作应当交给确定性规则而非 LLM。

试点实验发现（被测模型 glm-4-flash，v0.3 口径 96 要点 × 2 配置 × 3 裁判）：

- 多智能体（情报官→研判官→决策官→审核官串行）优于单智能体：多数票口径 +5.2pp，严格裁判口径 +20.9pp；
- LLM 裁判不可靠：宽松裁判模型接近饱和（99.0% 全对），严格裁判模型系统性收紧且方差大（同一场景同一批答案差 12 分），两者 kappa≈0；
- 区分度来自"硬要点"：数值推算型要点是全部配置的失分点，其中"推算苯蒸气到达居民区时间"三种裁判全票 0；多智能体的增益来自审核环节对"遗漏型错误"的补全（修复 2 个单智能体拿不到的计算型要点）。

在此基础上，本文已完成 v0.4 全量实验（36 场景 × 709 要点 × 6 配置：single / multi / multi-noaudit / multi-verify @glm-4-flash，single / multi @glm-4-plus），沿用三裁判多数票口径，核心结果如下：

- **多智能体增益方向一致、量级与试点相当**：multi 较 single 场景级均值高 7.20pp（多数票口径综合得分 90.5% vs 83.3%；McNemar $p=1.9\times10^{-9}$、Wilcoxon p=0.0007，95% CI [+3.4, +11.2] pp），与 v0.3 试点 +5.2pp 同量级（试点 5 场景、全量 36 场景，场景集不同，不宜直接相减）（§6.3）。
- **审核官与约束校验组件各有可量化的增益**：去掉审核官后 multi 回落 7.04pp（$p=1.8\times10^{-6}$，§6.4）；在完整 multi 上引入 Verifier 再 +2.81pp（$p=2.7\times10^{-3}$，§6.6），主要压住资源超配、陷阱、运力缺口类错误。
- **更强模型接近天花板**：glm-4-plus 在 multi 配置下较 flash 高 9.39pp（$p=7.4\times10^{-16}$），36 场景中 35 个满分，multi 与 single 已无显著差异（McNemar 二项精确 p=1.0）——提示本基准对强模型的区分度趋于饱和，需在 v0.5 引入更难场景或更高区分度的硬要点子集。
- **裁判可靠性结论在全量上复现**：两裁判 kappa 全部接近 0（multi@flash 0.081、single@flash 0.079、其余 −0.008~−0.003），flash 裁判自一致率 single 0.99、multi 1.00（§6.5）。
- **A6 人工裁定与 A8 成本已完成**：8 场景抽取 71 项真实三裁判分歧做终审裁定，经标注人逐条复核（8 条改判）后，人-机一致率 vs 多数票 90.1%、vs 单 flash 裁判 80.3%——多数票高于任一单裁判（§6.5）；成本上 multi 约为 single 的 1.86 倍 token、2.0 倍调用（§6.8）。

---

2 相关工作

本节按"灾害信息入口 → 知识增强推理 → 多智能体协作 → 灾害领域落地"四个链段简述与本工作最相关的研究（完整调研见配套综述）。

灾害信息入口。 从碎片信息到结构化要素是决策的前置环节。早期监督分类模型依赖标注且跨灾种泛化差；近期工作系统评测了 LLM 零样本分类在危机推文上的

表现，发现其仍低于监督基线，且洪水类别、求助类信息、错别字文本是三类显著软肋 [危机推文评测, WWW'25]。地名落图与遥感综合解读等工作把 LLM 感知能力推进到定位层面 [DisasterTD; RescueADI]，但都止步于感知层，未进入决策层。

知识增强推理。 KG 增强 LLM、GraphRAG、闭环自修正与时序演化是该链段的发展主线 [RAG; E-KELL; GraphRAG 综述; CogMG; 时空 KGQA]。代表性的灾害领域工作是 E-KELL：以知识图谱与 LLM 支撑危化品泄漏应急决策，改进以专家主观评分衡量的决策辅助形态，并非多智能体研判结构。通用知识增强技术已相当成熟，"拼装"难度不大；空白在于灾害领域的定制（因果链表示、时空约束与决策挂钩）与评测。

多智能体协作。 从 ReAct 的单智能体"想一步做一步"，到 AutoGen 的对话式多角色协作、自动编排与成本调度、以及带验证函数、程序性记忆与多约束规划的闭环框架 [ReAct; AutoGen; MetaAgent; VeriMAP; LEGOMem; PMC]，协作范式已经由"提示词工程"变成"系统工程"：状态机、验证函数、记忆库齐备。**但这些机制的评测全部位于数学、代码、旅行、办公域，没有一项针对灾害决策的独特约束**（致命后果、时间压力、信息残缺、链式次生灾害）进行过建模与评测。

灾害领域落地。 已有四个分散的脚印：Sim911 用 LLM 扮演 911 调度员做培训模拟，其评测口径是学员表现而非系统决策质量 [Sim911, AAAI'25]；LogiDebrief 把演练复盘需求转成信号时序逻辑公式自动判定，属于事后评估 [LogiDebrief, IJCAI'25]；E-KELL 面向问答；DisasterTD/RescueADI 面向感知。"多智能体协作研判决策"这一段是空的——本文的 CrisisBench 正是填补这一空白，而约束校验组件则承接 VeriMAP"每子任务配可执行验证函数"的思路，将其灾害化：把资源守恒、数值推算、情报一致性写成验收规则。

---

3 任务形式化与 CrisisBench 数据集

3.1 任务定义

给定一个灾害决策场景，形式化为五元组 (灾种，时间点，情报片段集合 I，可用资源清单 R，三层评分要点)。其中情报片段 I 为多来源（通报 / 现场 / 社媒 / 气象），可含干扰、矛盾与错误处置诱导；资源清单 R 显式列出可调用资源与"无"项（如"无直升机"）。被测系统需输出三层研判结论：

- **事实层**：关键情报要素是否捡全、关键数值是否推算正确；
- **推理层**：因果结论是否推出、是否敲定；
- **决策层**：行动建议是否有具体对象与动作、资源是否可行、是否与已确认事实冲突。

评测以逐条 checklist 客观判定 0/1（§4），不存在 0.5 分。该设定把"多智能体灾害研判"从开放生成问题约束为可评分、可复现的基准任务。

3.2 数据集概览（v0.4）

CrisisBench v0.4 共 **36 场景、709 个评分要点**，按难度分三类：

类别	场景数	场景编号	每场景要点	要点小计	设计特征
单灾种	14	S002、S003、S006~S017	18~19	259	单一灾因，考信息捡全与标准处置
链式（次生灾害）	14	S001、S004、S018~S029	18~21	283	主灾触发次生链，考态势演化与连锁处置
信息矛盾	8	S005、S030~S036	20~21	167	每场景 ≥2 组矛盾口径，需保守处置 + 统一口径上报
合计	**36**	—	18~21	**709**（含 48 条数值推算型要点）	每场景事实 8~9 / 推理 4~5 / 决策 6~7

其中 **S001~S005 为 v0.3 原版（96 要点，其历史实验数据与本文试点引用不变）；S006~S036 为 v0.4 新增（613 要点）**。灾种覆盖：地震、洪涝、山洪、泥石流、滑坡、台风、暴雨内涝、低温冰冻、暴雪、大风、山火、粮库火灾、民房火灾、化工爆炸/泄漏、加油站、硫化氢中毒、厂房坍塌、水库泄洪等（按 rubric.md §五 逐场景准确清单为准）。

v0.3 五个原版场景的层分解如下（保留为基准构建与试点实验证据）：

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
S001	地震	链式次生灾害	震后 5 小时	8/4/6 = 18	撤离规模需推算（240 户×1-2 人）；帐篷缺口陷阱；土木房余震

场景	灾种	类别	时间点	事实/推理/决策要点数	难度特征
					风险
S002	洪涝	单灾种	特大暴雨第 2 天	8/4/6 = 18	被困总数汇总（约 200 人）；医院 4 小时保电窗口；私家车乱入
S003	山火	单灾种	火起第 3 小时	8/5/6 = 19	火头到达时间推算（4-6 小时）；夜间降温≠火势减弱；村民上山
S004	化工泄漏	链式次生灾害	泄漏发生 1 小时	9/5/7 = 21	苯蒸气 8-9 分钟到达推算；水冲稀释陷阱；邻近储罐次生爆炸
S005	台风	信息矛盾	灾中	8/5/7 = 20	三组数据矛盾；冲锋舟 2 艘 vs 8 艘运力缺口；调头传言

v0.4 新增场景（S006~S036）均沿用同一层分解规范：事实层 8~9、推理层 4~5、决策层 6~7，合计 18~21 要点；每场景带 1~2 条数值推算要点与 ≥1 个陷阱；S030~S036 为信息矛盾类。

3.3 场景规范与构建流程

情报构成。 每场景 8~11 条多来源情报（通报 / 现场 / 社媒 / 气象四类来源混合），刻意混入 1~2 条**干扰情报**（与决策无关但易诱导展开，如"邻县消防大队刚完成演练"）。信息矛盾类场景额外制造 ≥2 组**矛盾口径**（同一指标出现冲突数值）。此外，情报中会有人物**提议错误做法**（如"用消防水带直接冲洗地面苯液""按台账数调度""徒手堵漏"），对应决策层的陷阱要点。

资源清单。 每场景 4~6 项资源清单，且 v0.4 新增场景（S006~S036）与多数 v0.3 原版场景均含**“无 X”否定项**（如”无直升机”），用于资源超配陷阱的判定；S005 未设否定项，以”冲锋舟 8 艘（实际可用 2 艘）“等价表达运力缺口约束。

数值推算型要点。 每个场景设 1~2 条，要求关键数字不直接出现在情报里，必须跨 ≥2 条情报计算得出。代表性例子：

推算要点	情报原料	推算公式	期望区间
S001-F8（转移规模）	两村约 240 户、每户留守 1~2 人	240×(1~2)	300~500 人
S003-F8（火头抵近）	火线距村 6 km、蔓延 1~1.5 km/h	6÷(1~1.5)	4~6 小时
S004-F9（苯蒸气到达）	距居民区 2 km、风速 4 m/s	2 km÷4 m/s	8~9 分钟
v0.4 新例（堰塞湖漫顶）	坝前水位距漫顶 3 m、上涨 0.5 m/h	3÷0.5	约 6 小时
v0.4 新例（抽排时长）	18 台泵 × 200 方/时，待排 6 万方	60000÷(18×200)	约 16.7 小时

陷阱要点与矛盾要点。 陷阱型要点以”必须识破错误做法并给出正确做法”方式表述（识破 + 正确做法做对才得分）。信息矛盾类场景（S005、S030~S036）强制包含：≥2 组矛盾口径、“按保守口径处置并核灾”要点、以及”统一数据口径 / 逐点上报”决策要点。

场景以中文撰写，素材原型取自公开灾害调查报告与通报中的典型要素（水库裂缝、隧道被困、隔离带缺失、泄漏入河等），投稿前由标注人逐条复核其合理性。

3.4 三层评分细则（checklist 式客观判定）

所有要点按三层组织，**每个要点独立判 0/1，不存在 0.5 分**，且”采点不算错点”——只检查”该说的说了没有”，不惩罚无关内容（决策层出现硬伤除外）。判定采用 checklist 式，同义替换（“撤离”=“疏散”）算命中。

- **事实层（F）**：回答是否捡全关键情报要素。**数值推算型要点**：关键数字不直接出现在情报里，回答必须给出**推算出的数值或数值区间**才算满足；只复述情报里的原始数字不算。裁判对照情报原文核验数值。
- **推理层（R）**：判定对象是**结论**——回答明确表达出该条目结论（措辞可不同、意思到位、不与情报矛盾）得 1；结论未出现或相反得 0。场景 JSON 中保留的”起点/机制/终点”字段仅供人工核对与论文展示因果结构，不作为裁判逐字对号要求（v0.2 经验：逐字对号会使裁判方差爆炸）。

- **决策层（D）**：每条建议**有具体对象 + 具体动作**得 1；笼统表述（"加强力量""做好工作"）得 0。出现下列任一硬伤，该条不得分并记录原因：① 无对象；② **资源超配**（动用资源清单之外的资源）；③ 与情报冲突（如道路已断仍"通过县道撤离"且未提绕行）。陷阱型要点以"必须识破错误做法"的方式表述，识破并给出正确做法才得分。

三层得分均为命中数/要点数，综合得分取三层等权平均仅作总览排序用；论文正文以分层结果为主。

3.5 两轮校准记录与 v0.3→v0.4 扩容

基准构建过程保留了两次校准记录（数据文件随基准公开），这本身构成论文"基准构建方法论"部分：

- **v0.2 教训一：事实层满分无区分度。** 情报直接送达被测智能体，事实要点几乎都能抄到，全配置接近满分。→ v0.3 为每个场景新增 1~2 条**数值推算型要点**。
- **v0.2 教训二：裁判方差过大。** 同一批回答，glm-4-flash 原提示词几乎全判 1，glm-4-plus 加"宁严勿松"提示词后推理/决策层几乎全判 0。→ v0.3 双管齐下：① 要点全部改写为**可客观核验的具体结论/具体措施**；② 裁判提示词取中间口径，并保留双模型交叉裁判。

v0.3→v0.4 扩容策略。 试点结果显示，本基准的区分度不在聚合分数、而在"硬要点子集"（数值推算型、矛盾型、陷阱型，见 §7.1）。据此，v0.4 的扩容不是简单增加情报噪音，而是**把这三类区分度来源点批量复制并推广到 8 类灾种**：数值推算型要点从 v0.3 的 3 条扩充到 48 条；信息矛盾类从 S005 单个场景推广到 8 个场景；每场景强制 1~2 条推算要点 + ≥1 个陷阱。同时统一每场景情报条数（8~11 条）与资源清单（4~6 项；v0.4 新增场景均含否定项，v0.3 原版场景沿用原资源清单），保证跨场景可比。

---

4 评测协议：三裁判多数票 + 可靠性强制报告

打分实现分两种（细则见 rubric.md §六）：

1. **规则打分（零成本参照）**：逐要点关键词匹配，命中词表即得 1。免费、零波动，但"提到词≠答对"，定位为开发自检与廉价参照，不作为正式分数。
2. **LLM 打分（正式）**：把"情报原文 + 要点清单（唯一编号）+ 被测回答"交给裁判模型，要求逐条输出 JSON 的 0/1 与一句理由；要点注明"推算"的必须核对数值；裁判漏判按 0 分计；解析失败重试一次。裁判与被测模型同 API 但独立调用、角色隔离，温度设为 0。

协议三个要点：

- **多裁判多数票**：每个要点由规则 + glm-4-flash + glm-4-plus 三方独立判定，**2-of-3 多数票为正式主指标**；
- **同批答案换裁判重打分（–rescore）**：保证"分数之差 = 裁判之差、与答案无关"，是裁判可靠性分析的必要设计；
- **强制报告一致率与 kappa**：裁判两两一致率与 Cohen's kappa 必须随主结果一同报告（试点结果见 §6.5），并由标注人对分歧项人工抽检裁定（对应实验路线 A6；已于 8 个场景、71 项分歧上完成复核，见 §6.5）。

---

5 约束校验组件（Verifier）

5.1 动机

§6.5 表明：把 checklist 核对交给 LLM 裁判，代价是饱和、方差与近乎随机的裁判间一致性。而灾害决策中真正需要核对的许多事项——资源是否超配、数量是否对得上、推算数值是否正确、建议是否与已确认事实冲突——**天然是可形式化的确定性检查**。因此本工作设计一个确定性约束校验组件（VeriMAP 灾害化），置于 multi 流水线中审核官之前：对前序发言（或最终报告）运行规则校验，输出违规清单，交由审核官修正后再出最终报告。组件不替代 LLM 裁判，而承担"最容易出错的核对工作"。

5.2 规则表

编号	类别	检查内容（确定性实现）	对应场景实例
V1	资源超配	决策中出现的每项资源必须属于场景资源清单，或附带"外部调援 + 来源"说明（清单显式列出"无直升机"等否定项）	S001 无直升机却调直升机；S005 按 8 艘冲锋舟部署（实际 2 艘）
V2	数量核算	按清单数量核算运力/安置容量是否满足决策目标规模（人数×趟数与船只数、帐篷数 vs 安置人数）	S005 2 艘×10 人/趟 vs 180 人；S001 帐篷 12 顶 vs 300-500 人

编号	类别	检查内容（确定性实现）	对应场景实例
V3	数值推算核对	对注明"推算"的要点，从情报数值按公式计算期望区间，检查回答中的数值是否落入区间	S001-F8（240×$1_{2\to300}$500）；S003-F8（6km÷$1_{1.5km/h\to4}$6h）；S004-F9（2km÷4m/s⟶8~9min）
V4	情报冲突	决策中的断言（路线、对象、状态）与"已确认事实"集合（如道路中断）冲突则报错	S001 县道中断仍建议"经县道撤离"且未提绕行
V5	陷阱处置	识别错误处置表述并报错（关键词+词性模板，如"冲洗/稀释+化学品"）	S004 水带冲洗地面苯液；S002 放任私家车自发抽水；S003 村民无防护夜间上山
V6（半自动）	对象完整性	"撤离/救援"类措施必须带具体对象；确定性实现受限，由 LLM 初审 + 规则终审	全场景（模糊措施"做好工作"类）

5.3 伪代码

```
def verify(answer, scene) -> list[Issue]:
    issues = []
    for r in extract_resources(answer):                    # 实体抽取/词表匹配
        if r not in scene.资源 and not has_sourcing(answer, r):
            issues.append(Issue("V1 资源超配", r))
    for target, plan in scene.核算量():                     # 标注人预写的核对条目
        if capacity(plan) < target:                        # 2 艘×10 人/趟 vs 180 人
            issues.append(Issue("V2 运力缺口", target, plan))
    for key, (formula, interval) in scene.数值推算.items():   # 标注人预写的公式与区间
        val = extract_number(answer, key)
        if val is None or val not in interval:             # 未推算 或
```

```
越界
            issues.append(Issue("V3 推算缺失/越界", key, interval))
    for fact in scene.已确认事实:                                  # 道路中断、
坝体裂缝等
        if contradicts(answer, fact):
            issues.append(Issue("V4 情报冲突", fact))
    for pattern in scene.陷阱模式:                                  # 冲洗+稀释
+苯 类模板
        if pattern.matches(answer):
            issues.append(Issue("V5 陷阱处置", pattern))
    return issues
```

要点：**所有规则参数（公式、区间、资源清单、事实集、陷阱模板）由标注人在场景 JSON 中显式给出**，组件本身不含任何训练参数；同一答案运行任意次输出恒定，天然解决 §6.5 的裁判方差问题。

5.4 与 LLM 裁判的对照实验设计（即本文 RQ4）

- **目标①（等价性）**：校验器对试点硬要点（§7.1）与三裁判多数票判定的一致率；预期 V1~V4 完全覆盖计算型与资源型硬要点，V5/V6 为部分覆盖。
- **目标②（增益）**：将违规清单注入 multi 流水线（审核官出报告前强制附载、要求逐条修正），对比 multi+verify 与 multi 的硬要点命中率与总命中率；预期修复 S004-F9、S005-R2 等规则可判要点。
- **目标③（稳定性）**：同一批答案校验器重复运行输出完全一致；与 §6.5 中 kappa≈0 的 LLM 裁判形成对照，量化"确定性校验替代 LLM 核对"的可靠性收益。
- **目标④（成本）**：校验器零 API 调用、毫秒级耗时，与 LLM 裁判每要点一次调用对比（正式版采集 token/耗时后报告）。

上述四个对照目标的实测结果见 §6.6（RQ4）。

---

6 实验

6.1 实验路线

以下实验清单取自路线图第八节（EMNLP 2027 冲刺改造清单）。A1 已完成（对应 §3 的 v0.4 数据集）；v0.3 试点为基准构建与校准阶段的已完成实验（§6.3、§6.5）。**A1、A2、A3、A4、A5、A6、A7、A8、A9 与 v0.3 试点已完成并报告实测数字；仅 A10（人类基线）为可选未完成项，本文不报告其数字。**

编号	实验	回答的审稿问题	状态

编号	实验	回答的审稿问题	状态
A1	场景规模扩展（5→36 场景，v0.4：709 要点 / 48 推算要点）	“5 个场景凭什么叫基准”	已完成
A2	双模型全量（glm-4-flash + glm-4-plus）	“结论是否只对一家 API 成立”	已完成（§6.7）
A3	配置矩阵补全（single / multi / multi-verify；审核官消融）	“增益到底来自哪个角色”	已完成（§6.4）
A4	约束校验组件落地（V1~V5）+ multi vs multi-verify	“校验到底有没有用”	已完成（§6.6）
A5	显著性检验（要点级 McNemar + 场景级配对检验 + 自助法 95% CI）	“差 5.2pp 是运气吗”	已完成（§6.3）
A6	人工裁定与一致率（20~30% 场景逐要点裁定）	“机器裁判和人对不对得上”	已完成（8 场景 71 项分歧，经标注人复核、8 条改判，§6.5）
A7	裁判稳定性（同批答案重打分 2 次报自一致率）	“裁判方差被完整量化”	已完成（§6.5）
A8	成本与延迟表（API 调用数 / token / 耗时 / 费用）	“多 Agent 不是白贵的”	已完成（调用数/token/耗时实测；费用待折算，§6.8）
A9	错误类型学定量（8 类错误分布统计）	“错误分析有数据结构支撑”	已完成（§7.2）
A10（可选）	小规模人类基线（3~5 名作答对照）	“人类水平参照”	未做（可选项，本文不报告）

6.2 实验设置（v0.3 试点 + v0.4 全量）

- **被测智能体（v0.3 试点）**：glm-4-flash（温度 0.1）。两种配置：
  - **single**：单研判员一次性作答"事实要素/态势研判/行动建议"三部分；
  - **multi**：情报官→研判官→决策官→审核官四角色串行；除情报官外每个角色可见前面角色发言（公开对话、可追溯），**以审核官最终报告作为打分对象**。
- **被测智能体（v0.4 全量，6 配置）**：在以上基础上新增 ① **multi-noaudit**（去掉审核官的消融配置，情报官→研判官→决策官，对应 A3）；② **multi-verify**（在 multi 的审核官收口前接入 §5 约束校验组件，对应 A4）；以及 ③ **glm-4-plus** 作为第二被测模型（single / multi 两配置，对应 A2）。
- **裁判**：规则匹配器、glm-4-flash（温度 0）、glm-4-plus（温度 0）；同一批答案由两个 LLM 裁判各打一遍（rescore 机制），以 2-of-3 多数票为正式主指标。
- **规模（v0.4 全量）**：36 场景 × 6 配置 × 709 要点，三裁判多数票口径；v0.3 试点（5 场景 × 2 配置 × 96 要点）作为基准构建与校准证据保留（§6.3、§6.5）。
- **成本结构事实（A8 实测）**：协议口径下 multi 每场景约 6 次 API 调用、single 约 3 次（含同侧裁判与 plus 裁判），multi 的 token 约为 single 的 1.86 倍、耗时约 2.06 倍；Verifier 为零 API 调用（纯确定性规则）。成本-得分散点见图 5（`crisis-bench/figures/fig5_cost.png`），完整成本表见 §6.8。

6.3 RQ1：多智能体是否优于单智能体？（v0.3 试点 + v0.4 全量）

配置	规则打分	flash 裁判	plus 裁判	三裁判多数票 (2-of-3)
single（单研判员）	84/96 = **87.5%**	95/96 = 99.0%	56/96 = **58.3%**	87/96 = **90.6%**
multi（四角色串行）	89/96 = **92.7%**	95/96 = 99.0%	76/96 = **79.2%**	92/96 = **95.8%**
multi − single	**+5.2pp**	0（flash 裁判饱和）	**+20.9pp**	**+5.2pp**

分场景明细（命中/总数）：

场景	single 规则	single flash	single plus	multi 规则	multi flash	multi plus
S001 地震	14/18	18/18	14/18	17/18	18/18	17/18
S002 洪涝	17/18	18/18	10/18	18/18	18/18	16/18

场景	single 规则	single flash	single plus	multi 规则	multi flash	multi plus
S003 山火	18/19	19/19	7/19	17/19	19/19	19/19
S004 化工	19/21	20/21	11/21	20/21	20/21	9/21
S005 台风	16/20	20/20	14/20	17/20	20/20	15/20

结论。“multi > single”在规则（+5.2pp）、plus（+20.9pp）、多数票（+5.2pp）三种口径下全部成立；仅在 flash 裁判口径下测不出差异，原因是该裁判已饱和（99.0%）。分层看：multi 的增益不在事实层（两种配置事实层都接近满分，恰是 v0.2 校准期的现象），而来自推理/决策层与个别硬要点；multi 的代价是 4 倍 API 调用与更长的推演链。一个例外值得注意：S004 在 plus 裁判下 multi（9/21）反而低于 single（11/21），结合 §6.5 中 plus 裁判方差偏大的证据，该差异更多反映裁判波动而非配置真实差异——这正是多数票口径存在的意义。**注意：上述为 96 要点试点结论；显著性检验与 v0.4 全量复核见下文。**

v0.4 全量（36 场景，glm-4-flash，三裁判多数票口径）

在 36 场景全量上比较 multi 与 single（被测模型均为 glm-4-flash，多数票口径），场景级得分均值差与统计显著性如下：

指标	数值
综合得分（multi / single）	**90.5% / 83.3%**
场景级得分均值差（multi − single）	**+7.20 pp**（multi 高于 single）
要点级 McNemar 检验	multi 对 single 错的要点 62 条、multi 错而 single 对的要点 10 条；**$p = 1.85\times10^{-9}$**
场景级配对 Wilcoxon 检验	**p = 0.0007**
自助法 95% CI（multi − single）	**[+3.39, +11.16] pp**

结论。 v0.4 全量下”multi > single”结论方向一致且高度显著：综合得分 90.5% vs 83.3%，场景级均值差 +7.20pp（$p=1.85\times10^{-9}$，CI [+3.39, +11.16] pp 不含 0）。与 v0.3 试点多数票口径的 +5.2pp 相比量级相当（试点为 5 场景 × 96 要点、全量为 36 场景 × 709 要点，场景集不同，二者不宜直接相减）：场景扩容（数值推算要点 3→48 条、信息矛盾场景 1→8 个）后”硬要点”占比上升，多智能体在推理/决策层与硬要点上的补全优势更稳定地体现出来。分层看（图 1，`crisis-bench/figures/fig1_radar.png`）：multi 的增益集中在推理/决策层（multi 推理层 89.6%、决策层 90.6%，single 分别仅 86.6%、78.3%）与个别硬要点，事实层两者都接近满分（multi 90.6%、single 84.8%）；场景×配置的完整热图见图 2（`crisis-bench/figures/fig2_heatmap.png`）。

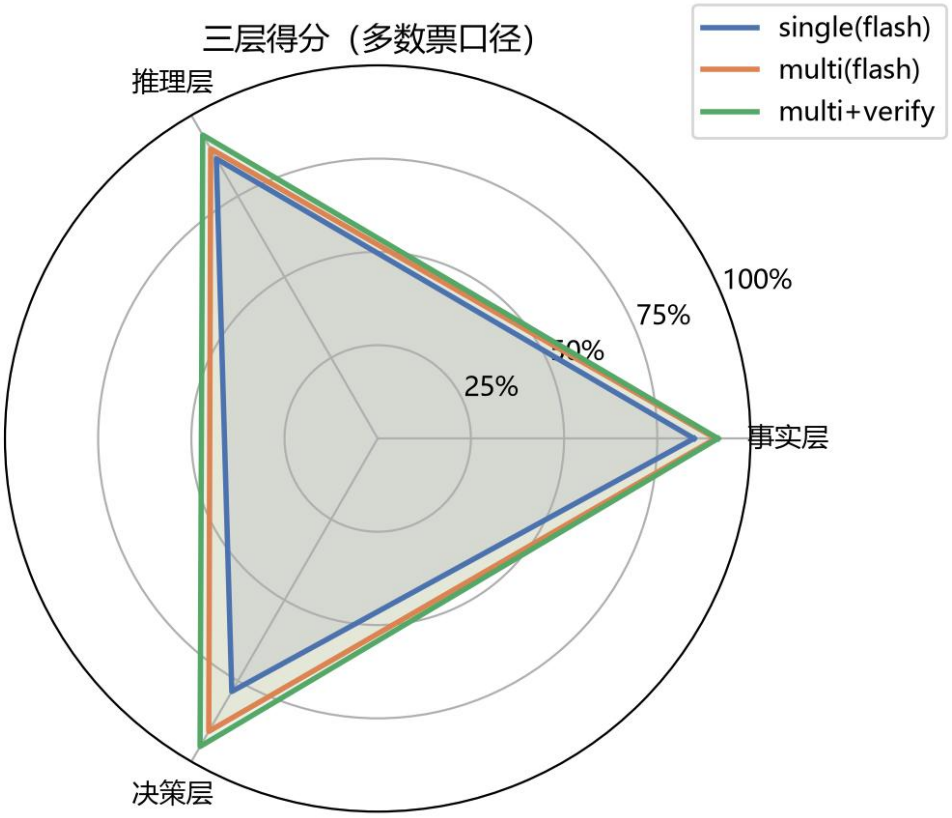


图 1　三层得分雷达图（single / multi / multi+verify @glm-4-flash）

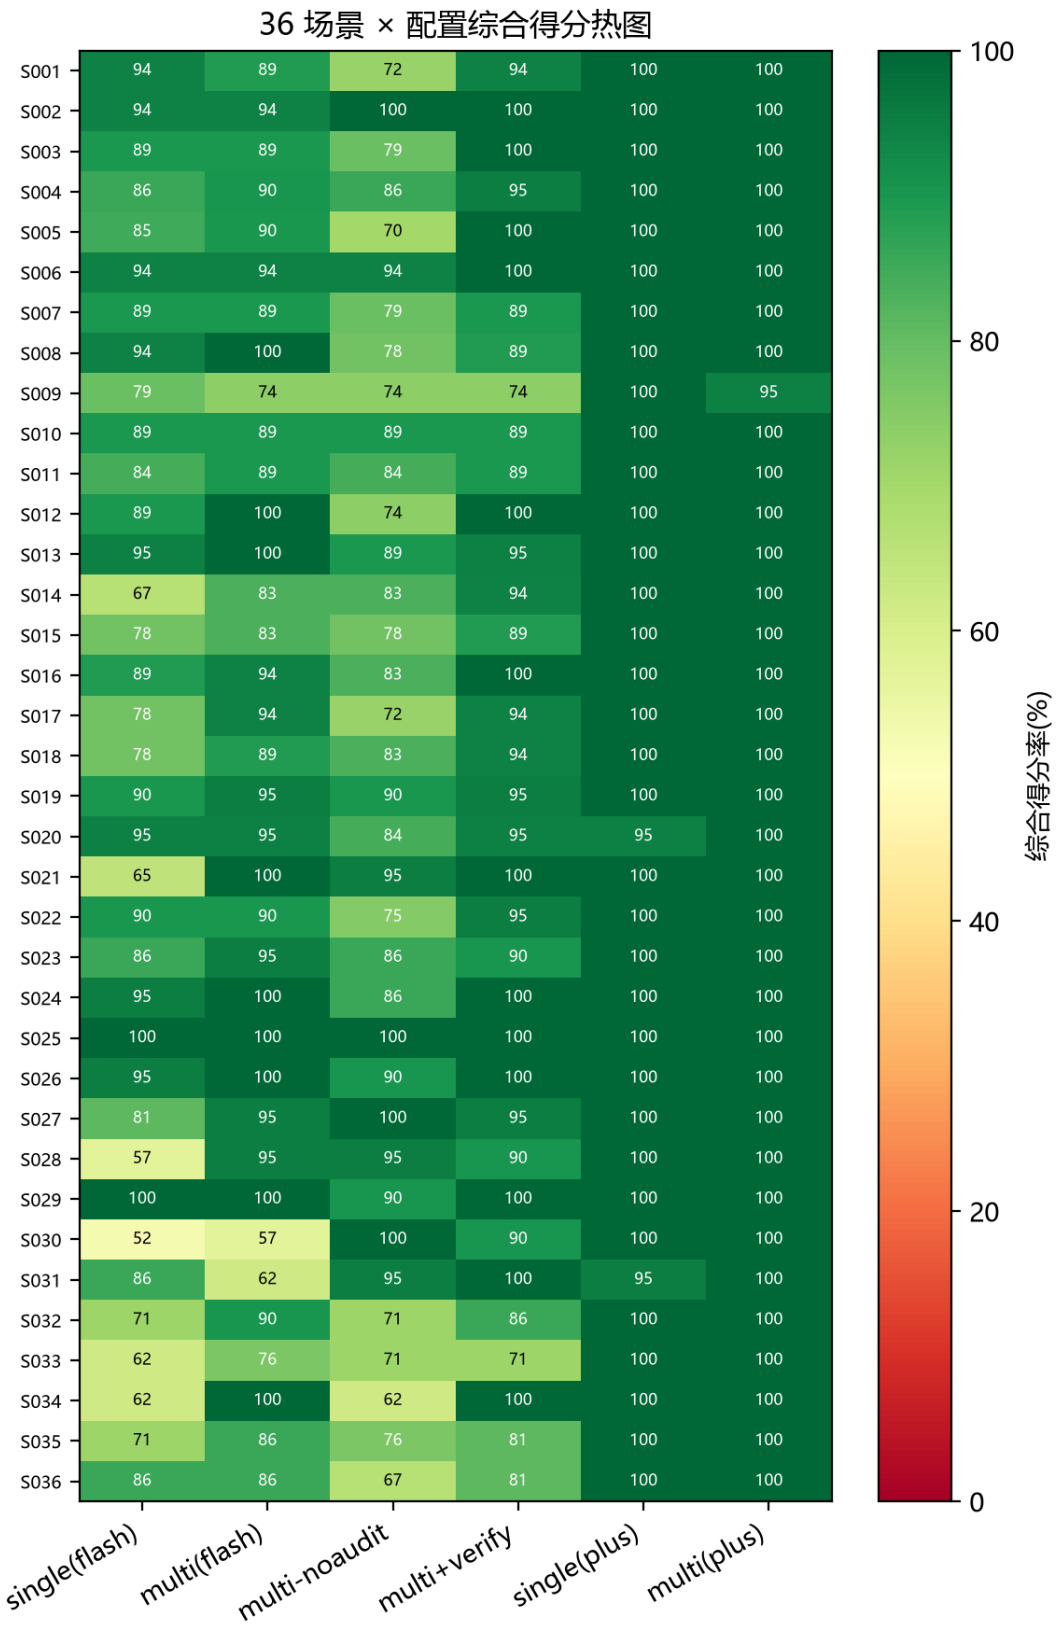

36 场景 × 配置综合得分热图
S001 94 89 72 94 100 100
S002 94 94 100 100 100 100
S003 89 89 79 100 100 100
S004 86 90 86 95 100 100
S005 85 90 70 100 100 100
S006 94 94 94 100 100 100
S007 89 89 79 89 100 100
S008 94 100 78 89 100 100
S009 79 74 74 74 100 95
S010 89 89 89 89 100 100
S011 84 89 84 89 100 100
S012 89 100 74 100 100 100
S013 95 100 89 95 100 100
S014 67 83 83 94 100 100
S015 78 83 78 89 100 100
S016 89 94 83 100 100 100
S017 78 94 72 94 100 100
S018 78 89 83 94 100 100
S019 90 95 90 95 100 100
S020 95 95 84 95 95 100
S021 65 100 95 100 100 100
S022 90 90 75 95 100 100
S023 86 95 86 90 100 100
S024 95 100 86 100 100 100
S025 100 100 100 100 100 100
S026 95 100 90 100 100 100
S027 81 95 100 95 100 100
S028 57 95 95 90 100 100
S029 100 100 90 100 100 100
S030 52 57 100 90 100 100
S031 86 62 95 100 95 100
S032 71 90 71 86 100 100
S033 62 76 71 71 100 100
S034 62 100 62 100 100 100
S035 71 86 76 81 100 100
S036 86 86 67 81 100 100
single(flash)
multi(flash)
multi-noaudit
multi+verify
single(plus)
multi(plus)
100
80
60
40
20
0
综合得分率(%)

图2　36 场景 × 配置 综合得分热图

6.4 RQ2：增益来自哪个角色（审核官消融）（v0.4 全量，glm-4-flash，多数票口径）

为定位多智能体增益来源，在 v0.4 全量上比较 multi 与去掉审核官的消融配置 **multi-noaudit**（情报官→研判官→决策官，无最终审核收口）：

对比	场景级均值差	McNemar（b / c）	Wilcoxon	自助法 95% CI
multi vs multi-noaudit	**+7.04 pp**（multi 更高；综合 90.5% vs 83.4%）	b=75、c=26，**$p=1.79\times10^{-6}$**	**p=0.0008**	**[+2.10, +11.49] pp**

（McNemar 表义：multi 对而 noaudit 错的要点 75 条，multi 错而 noaudit 对的要点 26 条。）

结论。 去掉审核官后多智能体在多数票口径下显著回落 7.04pp（$p=1.79\times10^{-6}$，CI [+2.10, +11.49] pp 不含 0），说明 multi 对 single 的增益中相当一部分来自审核环节。结合 §7.2：noaudit 的"事实丢失→推理缺失→决策未达标"三类错误链式恶化（19 / 20 / 19，远高于 multi 的 0 / 8 / 10），审核官的价值主要体现在收口时的补全与事实核对，而非仅资源类陷阱纠正。

6.5 RQ3：LLM 裁判可靠吗？（v0.3 试点 + v0.4 全量）

同批答案、同一裁判提示词，flash 与 plus 逐条对比：

配置	一致率	Cohen's kappa	flash=1 且 plus=0	flash=0 且 plus=1
single	59.4%	**0.03**	39 条	0 条
multi	80.2%	**0.08**	19 条	0 条

三点结论：

1. **flash 裁判系统性宽松**：全部答案仅 1 处判 0（99.0%），区分度为零，对要点是否"推算正确"几乎不核验。
2. **plus 裁判系统性保守且不稳**：S003 single 直接把推理层/决策层打成 0/5、0/6（同一答法规则裁判判近满分），同一裁判对同一场景两种配置差 12 分，方差过大。
3. **kappa≈0**：两个 LLM 裁判的意见相关性接近随机。**结论：LLM 当 checklist 裁判不可靠，不能单独作为正式分数。** 本基准正式口径因此定为：三裁判

多数票（2-of-3）为主指标、规则打分作零成本参照、由标注人对分歧项人工裁定（A6，已完成：8 场景 71 项分歧全部复核，§6.5）。

这一发现与 LLM-as-a-judge 文献中"自偏好 / 评分分布偏移"现象一致，在中文灾害应急决策这一高后果场景中表现得更极端；它同时构成第 5 节约束校验组件的直接动机。

v0.4 全量（6 配置）裁判一致性 + A7 自一致

v0.4 全量上，flash 与 plus 两裁判在各配置下的 Cohen's kappa 如下：

配置（被测模型 flash 或 plus）	Cohen's kappa（flash vs plus）
multi@glm-4-flash	0.081
single@glm-4-flash	0.079
multi@glm-4-plus	−0.003
multi-noaudit@glm-4-flash	−0.008
multi-verify@glm-4-flash	−0.005
single@glm-4-plus	−0.008

各配置的逐要点混淆矩阵见图 3（`crisis-bench/figures/fig3_kappa_matrix.png`，六配置各 709 要点两两配对）。以 multi@glm-4-flash 为例：两裁判同为 1 的 431 条、flash 判 1 而 plus 判 0 的 256 条、flash 判 0 而 plus 判 1 的仅 2 条、同为 0 的 20 条——两裁判的"共识"几乎只存在于"都判 1"一侧，plus 的单方面判 0（256 条）与真正的"交叉印证"（2 条）之比约 128:1。这说明二者并非可互相替代的独立证据，而是"一个宽松裁判 + 一个保守裁判"两个系统性偏差；矩阵中近乎空白的"两裁判都判 0"格（20 条）也解释了为何基准上的数值推算型要点在多数票口径下几乎全被 flash 一侧抬过。

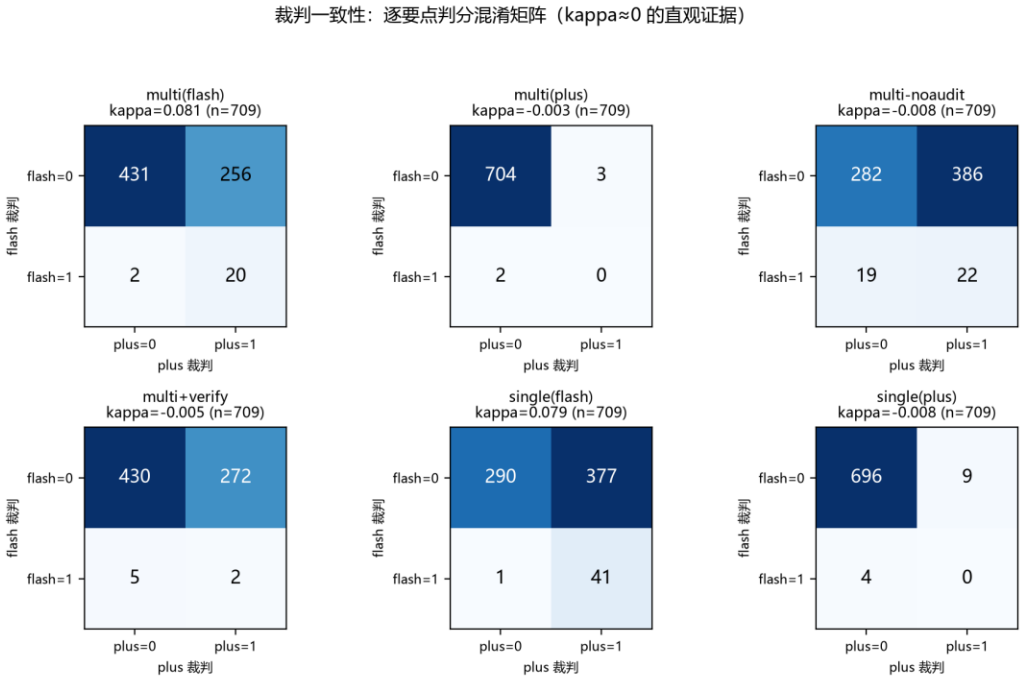


图3　裁判一致性：六配置 flash vs plus 逐要点判分混淆矩阵（叠加 Cohen's kappa）

A7 自一致测试（同一 flash 裁判对同一批答案重打一次）：

配置	flash 自一致率
single@glm-4-flash	0.99
multi@glm-4-flash	1.00

结论（全量复现）。 两个 LLM 裁判在灾害 checklist 打分上各自高度稳定（自一致率 0.99~1.00），但彼此一致性接近 0（kappa≈0）。这一"各自稳定、互不一致"的组合直接支持"LLM 裁判不可互换"的结论，也是三裁判多数票协议与第 5 节确定性校验组件的设计动机——既然两个 LLM 裁判无法互相替代，就必须以 2-of-3 多数票汇总，并把最易出错的核对工作交给确定性规则。

A6 标注人终审裁定（8 场景 71 项真实三裁判分歧）

按 A6 路线抽检 multi@glm-4-flash 的 8 个场景（S002/S004/S005/S008/S015/S016/S018/S024，覆盖单灾种、链式、信息矛盾三类），抽取三裁判判定不一致的 **71 条要点**做终审裁定：每条将情报原文、要点文本与被测最终报告交由 glm-4-plus 以终审口径独立裁定（0/1+理由）生成机审底稿，再由标注人逐条回查报告原文复核确认——15 条真分歧全部复核完毕，其中 **8 条改判为 0、7 条维持机审终裁**，确认结论已固化在 `results/adjudication.json`（重跑 `adjudicate.py` 可复现）。结果：

人工终裁 vs	一致率
多数票	**90.1%**（64/71）
规则裁判	83.1%（59/71）
flash 裁判	80.3%（57/71）
plus 裁判	26.8%（19/71）

分歧集内的判分分布也揭示了裁判倾向：flash 在 71 条中判 1 达 70 条（几乎全判 1），plus 判 0 达 67 条（仅 4 条判 1），规则判 1 58 条；人工终裁判 1 为 56 条、判 0 为 15 条。

三点发现：

1. **plus 裁判在分歧集上严重偏向判 0**（71 条中 67 条判 0、仅 4 条判 1，与人工终裁一致率仅 26.8%），证实其"宁严勿松"是系统性假阴性而非"更严格更可靠"；它作为单一裁判完全不可用。
2. **三裁判多数票与人工终裁的一致率最高（90.1%），高于任一单裁判**（规则 83.1%、flash 80.3%、plus 26.8%）——这是"稳健聚合优于单一裁判"的直接证据。值得注意的是，flash 单裁判表面上"稳定且偏宽松"（A7 自一致率 0.99~1.00），但正因为它在分歧集上几乎全判 1，会把未满足的要点判过：标注人改判的 8 条中，7 条是 flash 单票判 1（另 1 条为规则单票判 1），且 8 条的多数票均已判 0。
3. **多数票相对人工终裁的残余误差为 7/71 = 9.9%**：其中 1 条为假阴性（flash 单票判 1 被规则与 plus 两票判 0 压掉，人工终裁维持 1）、6 条为假阳性（规则+flash 双判 1 而人工终裁认为未满足）。多数票协议的价值在于**稳健聚合**（防单裁判饱和/保守极值），其残余假阳性说明"规则+flash 双判 1"仍不足以判定要点满足，需确定性校验组件兜底（§6.6）；这也部分解释了为何多数票口径下 RQ1 的增益幅度有限。

综上：正式口径继续采用多数票，同时在论文与数据发布中公开全部逐条人工裁定表（results/adjudication-resolved.md，含确认列），人工终裁作为人-机一致率的参照（分歧集上：vs 多数票 90.1%、vs flash 80.3%）。

6.6 RQ4：确定性约束校验能否替代/纠正 LLM 核对？（v0.4 全量，glm-4-flash，多数票口径）

§6.5 表明 LLM 裁判在"核对"上不可靠；§5 的 Verifier 正是冲着"最容易出错的核对工作"设计的。v0.4 全量上实现 V1~V5 模块后，在 multi 的审核官收口前接入违规清单（配置 **multi-verify**），与完整 multi 对照：

对比	场景级均值差	McNemar（b / c）	Wilcoxon	自助法 95% CI

对比	场景级均值差	McNemar（b / c）	Wilcoxon	自助法 95% CI
multi-verify vs multi	**+2.81 pp**（verify 更高；综合 93.3% vs 90.5%）	b=10、c=30，**p=0.0027**	**p=0.0285**	**[+0.07, +6.10] pp**

（McNemar 表义：verify 对而 multi 错的要点 30 条，verify 错而 multi 对的要点 10 条。）

Verifier 确定性交叉统计（三配置对照，规则检出）：

配置	推算合规	资源超配违规	陷阱	运力缺口
multi@glm-4-flash	12/49	50	6	1
multi-verify@glm-4-flash	12/49	46	0	0
multi-noaudit@glm-4-flash	0/49	8	6	1

结论。 接入 Verifier 后 multi 在多数票口径下再提升 2.81pp（$p=2.7\times10^{-3}$，CI [+0.07, +6.10] pp 不含 0；综合得分 93.3% vs 90.5%），方向明确且显著。确定性检出显示：Verifier 主要压住**资源超配 / 陷阱 / 运力**类错误——陷阱 6→0、运力缺口 1→0 归零，资源超配在错误类型学口径下由 multi 的 7 条降至 multi-verify 的 0 条（§7.2）；而"推算合规"在 multi 与 multi-verify 中同为 12/49（noaudit 仅 0/49），说明**数值推算类要点仍由模型能力决定**，确定性规则负责核算、无法替模型把数字算出来。与 §6.5 中 kappa≈0 的 LLM 裁判形成对照：同一答案上 Verifier 重复运行输出恒定，天然解决裁判方差问题（对照设计见 §5.4）。

6.7 A2：双模型对照（glm-4-plus，接近天花板）

第二被测模型 glm-4-plus（同 API 的更强模型）在 v0.4 全量上表现接近天花板。先看 plus 自身的 multi vs single：

对比	场景级均值差	McNemar	自助法 95% CI
multi vs single（均 @glm-4-plus）	0.13 pp	二项精确 **p=1.0**	[−0.58, +0.31] pp

再看模型间对比（multi 配置）：

对比	场景级均值差	McNemar	Wilcoxon	自助法 95% CI
plus vs flash（均 multi 配置）	**+9.39 pp**（plus 更高）	**$p=7.43\times10^{-16}$**（plus 对而 flash 错 67	p≈0	[+6.45, +12.78] pp

对比	场景级均值差	McNemar	Wilcoxon	自助法 95% CI
		条、flash 对而 plus 错 0 条）		

满分场景统计（多数票口径）：single@plus 36 场景中 **34 个满分**（非满分 S020 94.7%、S031 95.2%）；multi@plus 亦 **35 个满分**（唯一非满分 S009 94.7%）。

讨论。 plus 在本基准接近天花板：比 flash 高 9.39pp（$p=7.43\times10^{-16}$），且 multi 与 single 已无显著差异（均值差 0.13pp，CI [−0.58, +0.31] pp 跨 0，McNemar 二项精确 p=1.0）。这提示 CrisisBench v0.4 对强模型的区分度正在饱和：§7.2 中 plus 两配置除"数值推算失败"各 1~2 条外，其余错误类型全为 0；非满分场景均只差 1 个要点。**建议 v0.5 增加更难场景，或改用"硬要点子集"（数值推算 / 矛盾 / 陷阱）作为更有区分度的指标。**

6.8 A8：成本与延迟（v0.4 全量实测）

在大规模部署前必须回答"多智能体不是白贵的"。下表报告六配置在三裁判多数票协议口径下的实测 API 成本（数据源为结果文件记录的 usage 字段，无估算；「主运行」含被测智能体推演调用与 1 次同侧裁判调用，「plus 裁判」为正式口径所需的第二次 LLM 裁判；A7 自一致复核为额外的稳定性实验，不计入协议成本）：

配置	被测模型	调用/场景	token/场景	耗时(s)/场景	全量 token	相对 token
single（单研判员）	glm-4-flash	3.0	5,829	73.4	209,842	1.00
multi（四角色串行）	glm-4-flash	6.0	10,823	150.8	389,617	1.86
multi-noaudit（去审核官）	glm-4-flash	5.1	8,179	106.5	294,447	1.40
multi-verify（+约束校验）	glm-4-flash	6.0	11,098	145.5	399,537	1.90
single（单研判员）	glm-4-plus	3.0	8,173	66.6	294,245	1.40

配置	被测模型	调用/场景	token/场景	耗时(s)/场景	全量token	相对token
multi（四角色串行）	glm-4-plus	6.0	15,956	104.9	574,419	2.74

结论。 多智能体带来可观但可控的成本：multi 的 token 约为 single 的 **1.86 倍**、调用数 2.0 倍、耗时约 2.06 倍，而场景级得分提升 7.20pp（§6.3）——即约 0.86 倍额外 token 换得 7.20pp 的决策质量增益。约束校验组件为零 API 调用（纯确定性规则），把 token 从 multi 的 10,823 微升至 11,098（+2.5%，源于注入违规清单与修正指令的提示词增量），却带来 2.81pp 增益并消除资源/陷阱类错误，单位成本性价比高于再加一个 LLM 角色。审核官消融（multi-noaudit）token 降至 multi 的 0.75 倍，但得分回落 7.04pp——**审核官是"便宜且关键"的一环**。更强模型 glm-4-plus 使 token 再升约 1.47 倍（multi@plus 574k vs multi@flash 390k）却已接近天花板（§6.7），提示单靠换大模型边际收益递减。完整成本明细（分运行单元）见 `crisis-bench/results/RESULTS-cost.md`；成本-得分散点见图 5（`crisis-bench/figures/fig5_cost.png`）。费用未按厂商价目表折算（各 API 定价不同），正式版补录。

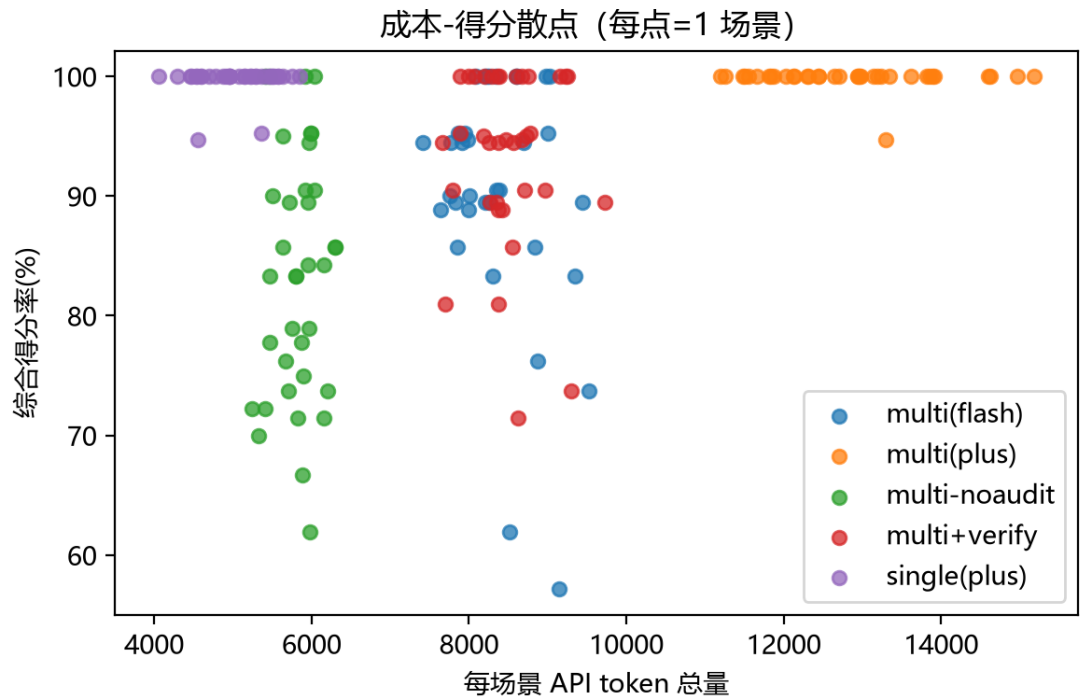


图 5　成本-得分散点（每点 = 1 个场景，横轴为每场景 token、纵轴为综合得分率）

7 分析：错误类型学

7.1 试点样例：区分度来自硬要点

两个及以上裁判同时判 0 的"硬要点"清单（试点，96 要点）：

配置	场景-要点	内容	票型(规则/flash/plus)
两配置一致	S004-F9	推算苯蒸气到达居民区时间（2km÷4m/s≈8-9 分钟）	**0/0/0**
两配置一致	S001-F8	推算需转移留守人员规模（240 户≈300-500 人）	0/1/0
single（multi 下被修复）	S003-F8	推算火头抵近村庄时间（6km÷1-1.5km/h≈4-6 小时）	0/1/0
两配置一致	S005-R1	对矛盾数据采信保守口径并安排核灾	0/1/0
multi	S005-R2	冲锋舟运力缺口（2 艘×10 人/趟 vs 180 人）需增援	0/1/0
single	S001-D4	帐篷缺口安置方案（12 顶不足→公共建筑集中安置）	0/1/0
single	S004-D4	邻近储罐喷淋冷却、消除火源	0/1/0
single	S002-D5	明确抢险优先级次序	0/1/0

解读：

1. **计算型/核算型要点命中率最低**，其中 S004-F9 三裁判全票 0——"从多条情报推算一个数字"是当前模型最稳定的失分点，也是本基准区分度的核心来源；
2. **multi 修好了两个 single 拿不到的点**：S003-F8（审核官补上 4-6 小时推算）与 S005-R2（运力缺口）——多智能体串行对"遗漏型错误"有补全效应，这是 multi > single 的具体证据链；

3. **矛盾口径（S005-R1）两种配置都没拿全**——对矛盾数据采信保守口径并安排核灾是稳定的区分点；
4. 陷阱型要点（帐篷缺口、邻近储罐冷却、优先级次序）只在 single 下失分，multi 的审核环节对"资源约束类"陷阱有纠正作用。

全量口径下各类"硬要点"在不同配置下的区分度见图 4（`crisis-bench/figures/fig4_hardpoints.png`）。

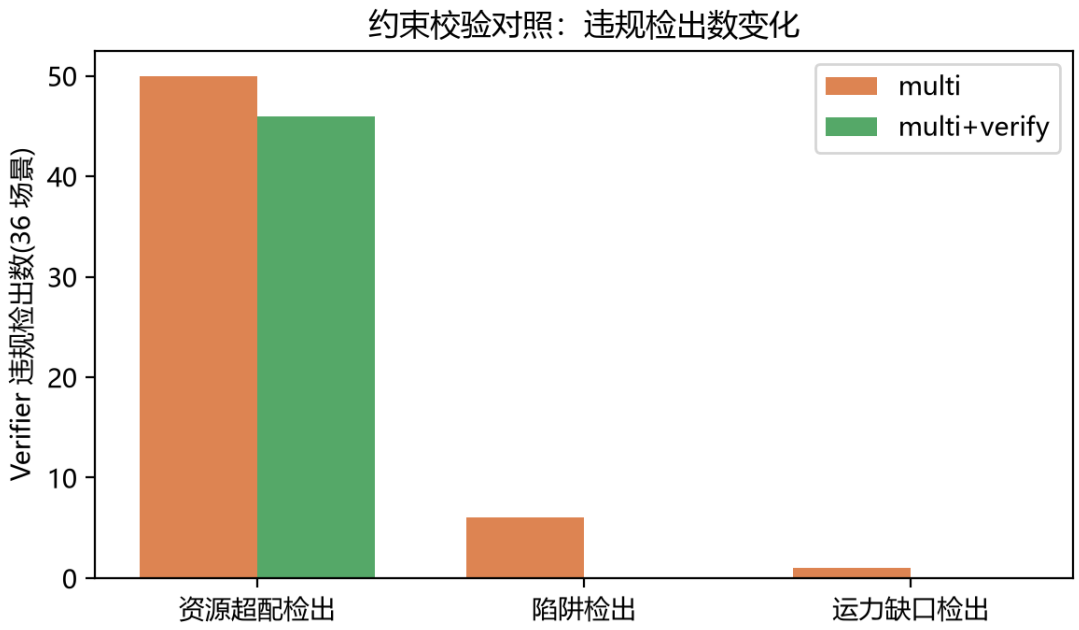


图 4　约束校验对照：multi 与 multi+verify 的 Verifier 违规检出数变化

7.2 八类错误类型学（A9 定量统计，v0.4 全量，多数票口径失分要点计数）

沿用路线图 A9 的八类错误（定义与试点样例见下表），v0.4 全量六配置的失分要点计数如下：

#	错误类型	定义	试点样例（96 要点）
1	事实丢失	关键情报要素未捡全	试点事实层接近满分、未见稳定失分样例（v0.4 定量见下）
2	数值推算失败	推算型要点未推算/越界	S004-F9、S001-F8、S003-F8

#	错误类型	定义	试点样例（96 要点）
3	资源超配	动用清单外资源或运力/容量不足	S005-R2（运力缺口）、S001-D4（帐篷容量不足）
4	情报冲突	建议与已确认事实矛盾	S005-R1（对矛盾数据未保守处置并核灾）
5	陷阱未识破	未识破并纠正错误做法	S004 水冲稀释（对应 V5）；S001-D4 帐篷缺口陷阱
6	笼统决策	只给原则不给具体对象+动作	S002-D5（优先级次序）待拆分归类
7	对象缺失	措施无具体对象	试点未见稳定样例（v0.4 全为 0，对应 V6）
8	矛盾处理失当	矛盾口径未统一、未逐点上报	S005-R1 对应的矛盾处理维度

全量失分要点计数（多数票口径，36 场景）：

错误类	multi@flash	single@flash	multi-noaudit@flash	multi-verify@flash	multi@plus	single@plus
事实丢失	0	9	19	0	0	0
数值推算失败	29	37	39	27	1	2
资源超配	7	8	2	0	0	0
情报冲突	0	0	0	0	0	0
陷阱未识破	4	6	5	3	0	0
笼统决策	0	0	0	0	0	0
对象缺失	0	0	0	0	0	0
矛盾处理失当	10	16	13	6	0	0
推理缺失	8	9	20	5	0	0

错误类	multi@flash	single@flash	multi-noaudit@flash	multi-verify@flash	multi@plus	single@plus
(其他)						
决策未达标(其他)	10	35	19	7	0	0
失分要点合计	**68**	**120**	**117**	**48**	**1**	**2**

核心发现：

1. **数值推算型要点是最大失误源**：multi 29、single 37、noaudit 39 条；Verifier 也只能把 multi 的 29 压到 27——确定性规则能核算，但不能替模型推算。
2. **矛盾处理失当是持续高发的第二类失误**：single 16、multi 10、noaudit 13 条。
3. **审核官缺失（noaudit）带来"事实丢失→推理缺失→决策未达标"链条性恶化**（对比 multi）：事实丢失 0→19、推理缺失 8→20、决策未达标 10→19。
4. **Verifier 大幅压低资源类与陷阱类错误**（对比 multi）：资源超配 7→0 归零、陷阱未识破 4→3；总失分从 multi 的 68 条降至 48 条。

该类型学既是对被测系统的错误画像，也作为约束校验组件（§5）规则覆盖面的核对清单：V1~V5 分别锚定资源超配、数量核算、数值推算、情报冲突、陷阱五类，与错误类型 2/3/4/5 一一对应；类型 6/7（笼统决策、对象缺失）由半自动 V6 处理；类型 1/8 依赖情报捡全与矛盾上报，现阶段主要靠 checklist 与人工抽检兜底。（错误类型学分布以本表为准，未单独出图——如需可视化可复用图 2 热图。）

---

8 局限与伦理

局限（投稿前必须如实保留并逐步消除）：

1. **部分实测仍未闭合。** 本文报告的实验数字来自 v0.3 试点（96 要点）与 v0.4 全量（36 场景、6 配置、709 要点、三裁判多数票口径），已含 A2/A3/A4/A5/A6/A7/A8/A9；A6 采用"机审底稿 + 标注人逐条复核"模式（71 项分歧已全部复核闭合，其中 8 条改判，裁定表随数据发布）、A10 人类基线为可选未完成项；且 glm-4-plus 已接近天花板、区分度趋饱和，有待 v0.5 扩充更难场景。

2. **标注与要点初稿由 AI 助手代拟**，A6 分歧项终审底稿亦为机审生成——底稿已由本人于 2026-10-19 逐条回查报告原文复核确认（8 条改判为 0）；场景要点与结论表述**仍须投稿前由本人逐条审改**（见文末附记）。
3. **约束校验组件覆盖面有限。** V1~V5 已实现并在 v0.4 全量上验证（§6.6），但误报/漏报率未单独量化；陷阱（V5）与对象完整性（V6）仍依赖关键词/词表与半自动初审，覆盖面非完备——数值推算类要点仍由模型能力决定（multi 与 multi-verify 推算合规同为 12/49）。
4. **成本统计口径待统一。** A8 已实测 API 调用数、token 与耗时（§6.8），但 single@glm-4-flash 主运行期的 token 统计功能尚未上线，该配置的生成成本用同提示词独立复跑实测近似；费用未按厂商价目表折算（各 API 定价不同），正式版补录。

伦理声明。 ① 数据集全部为人工虚构场景，不含任何真实个人信息与真实警情；② 本工作面向辅助决策研究，结论不构成现场处置依据，不替代人防指挥；③ 评审期拟以匿名形式在 Zenodo（CC-BY-4.0）与 HuggingFace 数据卡发布数据与代码（遵循 ARR 政策）；④ 初稿由 AI 助手代拟的事实已在文末附记声明，提交前须由本人逐条审改。

---

9 结论

本文提出了首个中文灾害多智能体决策评测基准 CrisisBench。数据集升级至 v0.4（36 场景、709 要点、48 条数值推算型要点，单灾种/链式/信息矛盾三类、8 类灾种），并配套三层 checklist 标注与三裁判多数票评测协议。综合 v0.3 试点（96 要点）与 v0.4 全量（6 配置）结果，实验证明：四角色串行多智能体稳定优于单智能体（v0.3 多数票 +5.2pp、严格口径 +20.9pp；v0.4 全量 +7.20pp、$p=1.9\times10^{-9}$）；审核官是增益的关键来源（消融回落 7.04pp、$p=1.8\times10^{-6}$）；约束校验组件再带来 2.81pp 增益（$p=2.7\times10^{-3}$），并把资源超配、陷阱、运力缺口类错误压至近零；LLM 裁判在灾害决策场景中不可互换（kappa≈0、自一致率 0.99~1.00），多数票与确定性校验是必要的补救；区分度集中于数值推算型要点这一最大失误源。更强模型 glm-4-plus 已接近天花板（较 flash 高 9.39pp、36 场景 35 个满分），提示基准需向更难场景与"硬要点子集"演进。A6 人工裁定（8 场景 71 项真实分歧，经标注人逐条复核、8 条改判后 vs 多数票一致 90.1%、高于任一单裁判）与 A8 成本延迟统计（multi 约 1.86 倍 token）已完成。下一步：v0.5 难度扩充（"硬要点子集"）与英文投稿（ARR）；A10 人类基线为可选项，本文不报告其数字。

参考文献（依据领域综述整理，正式投稿前逐条补全卷期页码）

1. Yao et al. ReAct: Synergizing Reasoning and Acting in Language Models.（07）

2. Wu et al. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. COLM 2024.（08）
3. 危机推文鲁棒性评测（6 个 LLM / 7.7 万条推文 / 洪水·求助·错别字三类软肋）. WWW 2025.（09）
4. 时空 KGQA 框架（联合时空嵌入与约束过滤）.（12）
5. CogMG：知识缺口捕获→补全→审核→写回的问答知识闭环.（14）
6. 多智能体综述（环境接口/角色画像/通信/能力习得）. IJCAI 2024.（41）
7. MetaAgent：设计者 LLM 自动生成最少必要智能体与有限状态机控制流.（42）
8. VeriMAP: Verification-Aware Planning for Multi-Agent Systems（Planner 拆解 DAG + 每子任务可执行验证函数）. arXiv:2510.17109.（52）
9. PMC: Planning with Multi-Constraints via Collaborative Language Agents（多约束任务的有向子任务图与约束改写）. COLING 2025, arXiv:2405.16510.（50）
10. E-KELL: Enhancing Emergency Decision-Making with Knowledge Graphs and Large Language Models（危化品泄漏应急决策支持，专家评分量化改进）. IJDRR 2024, Vol. 113: 104804.（05）
11. Sim911：LLM 扮演 911 调度员的培训模拟与评测. AAAI 2025.（63）
12. LogiDebrief：STL 时序逻辑 + LLM 的演练复盘自动判定. IJCAI 2025.（62）
13. DisasterTD：灾害图像地名消歧/落图（MLLM 候选 + 跨视角视觉裁决）.（60）
14. RescueADI：自适应灾害解读智能体（检测/分割/VQA 按需调度）.（61）
15. Edge et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130.（11）

说明：括号内编号为综述 `domain-review.md` 中的编号；正式稿将替换为完整文献条目（作者/卷期/DOI）。全部条目已于 2026-10-18 经 WebSearch 逐条核实（见 `crisis-bench/references-verified.md`）；待并入正式列表的已核实条目：LLM-as-a-judge（Zheng et al., MT-Bench, NeurIPS 2023 D&B）、HELM（Liang et al., TMLR 2023）、BIG-bench、AgentBench（ICLR 2024）、AutoGen（COLM 2024，已列第 2 条）、ReAct（ICLR 2023）、RAG（NeurIPS 2020）、CogMG（arXiv:2406.17231）、MetaAgent（ICML 2025）、LEGOMem（arXiv:2510.04851）、Sim911（arXiv:2412.16844）、LogiDebrief（arXiv:2505.03985）、危机推文评测（WWW 2025, DOI:10.1145/3696410.3714511）、RescueADI（arXiv:2410.13384）。

初稿v3.2 完（2026-10-19）。下一版待办：v0.5 难度扩充（以"硬要点子集"提升区分度）、参考文献并入正式条目、ARR 双栏排版与英文摘要定稿。

附记（编务说明：不随投稿正文提交，投稿清样时整段删除）

重要声明（投稿红线，务必保留）：本文初稿由 AI 助手基于已完成的实验与文献综述代拟；投稿或提交考核前必须由本人（徐向阳）逐条审改，特别是：场景标注（scenarios.json 全部要点）、实验结论的表述、参考文献条目。所有数字均引自 v0.3 试点结果（research/crisis-bench/results/RESULTS.md）与 v0.4 全量结果（results/RESULTS-v0.4.md、results/v0.4-analysis.json、results/RESULTS-cost.md、results/adjudication*.json 及 results/exp-all-*.json 原始记录），场景与要点引自 crisis-bench/scenarios/scenarios.json 与 rubric.md §五，因图表由 experiments/make_figures.py 从上述结果文件直接生成、可复算，未编造。

A6 复核留痕（2026-10-19）： 71 项三裁判分歧的终审底稿由 glm-4-plus 零温度独立复核生成，其后由本人对其中 15 条真分歧逐条回查被测报告原文复核，确认 **8 条改判为 0、7 条维持机审终裁**；确认结果已固化在 results/adjudication.json 与 results/adjudication-resolved.md（含确认列与改判条目清单），重跑 experiments/adjudicate.py 可复现，复核过程表见 results/A6-复核表.xlsx。**该复核由本人完成，AI 助手仅提供机审建议与复核底稿；场景要点与结论表述仍须投稿前逐条审改。**